



**TUGAS AKHIR - TF 181801**

**DETEKSI ANOMALI SUARA MESIN NORMAL DAN ABNORMAL DENGAN  
METODE *SUPERVISED* DAN *UNSUPERVISED LEARNING***

**BAGUS ADHI HERLAMBAANG**

**NRP. 02311840000083**

Dosen Pembimbing:

Dr. Suyanto, S.T., M.T.

Bagus Tris Atmaja, S.T., M.T., P.hD.

DEPARTEMEN TEKNIK FISIKA

Fakultas Teknologi Industri dan Rekayasa Sistem

Institut Teknologi Sepuluh Nopember

Surabaya 2022

*Halaman ini sengaja dikosongkan*



***FINAL PROJECT - TF 181801***

***DETECTION OF NORMAL AND ABNORMAL MACHINE SOUND  
ANOMALIES WITH SUPERVISED AND UNSUPERVISED LEARNING  
METHODS***

**BAGUS ADHI HERLAMBAANG**

**NRP. 02311840000083**

Supervisors:

Dr. Suyanto, S.T., M.T.

Bagus Tris Atmaja, S.T., M.T., P.hD.

***DEPARTMENT OF ENGINEERING PHYSICS***

***Faculty of Industrial Technology and System Engineering***

***Institut Teknologi Sepuluh Nopember***

***Surabaya 2022***

*Halaman ini sengaja dikosongkan*

## PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan di bawah ini.

Nama : Bagus Adhi Herlambang  
NRP : 02311840000083  
Departemen / Prodi : Teknik Fisika / S1 Teknik Fisika  
Fakultas : Fakultas Teknologi Industri & Rekayasa Sistem (FTIRS)  
Perguruan Tinggi : Institut Teknologi Sepuluh Nopember

Dengan ini menyatakan bahwa Tugas Akhir dengan judul “**DETEKSI ANOMALI SUARA MESIN NORMAL DAN ABNORMAL DENGAN METODE SUPERVISED DAN UNSUPERVISED LEARNING**” adalah benar karya saya sendiri dan bukan plagiat dari karya orang lain. Apabila di kemudian hari terbukti terdapat plagiat pada Tugas Akhir ini, maka saya bersedia menerima sanksi sesuai ketentuan yang berlaku.

Demikian surat pernyataan ini saya buat dengan sebenarnya-benarnya.

Surabaya, 16 Juni 2022

Yang membuat pernyataan,

Bagus Adhi Herlambang  
NRP. 02311840000083



*Halaman ini sengaja dikosongkan*

**LEMBAR PENGESAHAN**  
**TUGAS AKHIR**

**DETEKSI ANOMALI SUARA MESIN NORMAL DAN ABNORMAL DENGAN  
METODE *SUPERVISED* DAN *UNSUPERVISED LEARNING***

**Oleh:**

**Bagus Adhi Herlambang**

**NRP. 02311840000083**

**Surabaya,**

**Menyetujui,  
Pembimbing I**

**Menyetujui,  
Pembimbing II**

**Dr. Suyanto, S.T., M.T.**  
**NIP. 19711113 199512 1 002**

**Bagus Tris Atmaja, S.T., M.T., P.hD.**  
**NIP. 19860810201504 1 002**

**Mengetahui,  
Kepala Departemen  
Teknik Fisika FTI-ITS**

**Dr. Suyanto, S.T., M.T.**  
**NIP. 19711113 199512 1 002**



*Halaman ini sengaja dikosongkan*

# LEMBAR PENGESAHAN

## DETEKSI ANOMALI SUARA MESIN NORMAL DAN ABNORMAL DENGAN METODE *SUPERVISED* DAN *UNSUPERVISED LEARNING* TUGAS AKHIR

Diajukan Untuk Memenuhi Salah Satu Syarat  
Memperoleh Gelar Sarjana Teknik  
pada  
Progam Studi S-1 Departemen Teknik Fisika  
Fakultas Teknologi Industri & Rekayasa Sistem (FTIRS)  
Institut Teknologi Sepuluh Nopember

Oleh:

**BAGUS ADHI HERLAMBAANG**

**NRP. 02311840000083**

Disetujui oleh Tim Penguji Tugas Akhir:

- |   |       |                 |
|---|-------|-----------------|
| 1. Dr. Suyanto, S.T., M.T.              | ..... | (Pembimbing I)  |
| 2. Bagus Tris Atmaja, S.T., M.T., Ph.D. | ..... | (Pembimbing II) |
| 3. Dr. Katherin Indriawati, S.T., M.T.  | ..... | (Ketua Penguji) |
| 4. Ir. Ya'umar, M.T.                    | ..... | (Penguji I)     |
| 5. Detak Yan Pratama, S.T., M.Sc.       | ..... | (Penguji II)    |

**SURABAYA**

**2022**

*Halaman ini sengaja dikosongkan*

# **PERANCANGAN *FAULT TOLERANT CONTROL* (FTC) PADA *REGENERATIVE ANTI-LOCK BRAKING SYSTEM* DENGAN MOTOR BLDC UNTUK APLIKASI MOBIL LISTRIK DENGAN KESALAHAN PADA AKTUATOR**

**Nama** : Bagus Adhi Herlambang  
**NRP** : 02311840000083  
**Departemen** : Teknik Fisika FTIRS - ITS  
**Dosen Pembimbing** : Dr. Suyanto, S.T., M.T.  
Bagus Tris Atmaja, S.T., M.T., Ph.D.

## **ABSTRAK**

Deteksi anomali suara mesin merupakan salah satu implementasi dari *deep learning* di industri dalam hal monitoring kondisi mesin. Anomali dalam suara yang dihasilkan oleh mesin dapat menunjukkan adanya indikasi kesalahan atau kerusakan, dengan melakukan deteksi anomali lebih awal dapat menghindari serangkaian masalah terutama dalam hal pemeliharaan prediktif. *Anomaly detection* umumnya termasuk ke dalam *unsupervised learning* karena sulitnya mendapatkan informasi data normal atau anomali di industri. Pada penelitian tugas akhir kali ini akan menganalisis metode terbaik antara *unsupervised learning* dan *supervised learning* untuk deteksi anomali suara mesin normal dan abnormal. Metode *unsupervised learning* menggunakan model MobileNet V2 dan Auto Encoder sedangkan untuk *supervised learning* menggunakan model *Bidirectional Generative Adversarial Network* (BiGAN).

**Kata Kunci:** *Anomaly detection, deep learning, supervised learning, unsupervised learning.*

*Halaman ini sengaja dikosongkan*

***FAULT TOLERANT CONTROL (FTC) DESIGN ON REGENERATIVE  
ANTI-LOCK BRAKING SYSTEM WITH BLDC FOR ELECTRIC CAR  
APPLICATION WITH FAULTS ON ACTUATOR***

***Name*** : Bagus Adhi Herlambang  
***NRP*** : 0231840000083  
***Department*** : Engineering Physics FTIRS - ITS  
***Supervisors*** : Dr. Suyanto, S.T., M.T.  
Bagus Tris Atmaja, S.T., M.T., Ph.D.

***ABSTRACT***

Detection of machine noise anomalies is one of the implementations of deep learning in the industry in terms of monitoring machine conditions. Anomalies in the sound produced by the machine can indicate an indication of fault or damage, by performing anomaly detection early one can identify problems, especially in predictive maintenance. Anomaly detection is generally included in unsupervised learning because of the difficulty of obtaining normal or anomalous information data in the industry. In this final study, we will analyze the best method between unsupervised learning and supervised learning to detect normal and abnormal machine noise anomalies. The unsupervised learning method uses the MobileNet V2 model and Auto Encoder while for supervised learning it uses the Bidirectional Generative Adversarial Network (BiGAN) model.

***Keywords:*** *Anomaly detection, deep learning, supervised learning, unsupervised learning.*

*Halaman ini sengaja dikosongkan*

## KATA PENGANTAR

Puji syukur kepada Allah SWT atas rahmat dan karunia-nya sehingga penulis dapat menyelesaikan Tugas Akhir dengan lancar. Selama 4 bulan pengerjaan Tugas Akhir yang berjudul “DETEKSI ANOMALI SUARA MESIN NORMAL DAN ABNORMAL DENGAN METODE *SUPERVISED* DAN *UNSUPERVISED LEARNING*”, penulis telah mendapat banyak bimbingan serta masukan dari berbagai pihak, sehingga penulis dapat menyelesaikan Tugas Akhir ini dengan lancar. Dalam kesempatan ini penulis hendak mengucapkan terima kasih kepada pihak yang telah membantu, diantaranya kepada:

1. Bapak Dr. Suyanto, S.T., M.T., selaku Kepala Departemen Teknik Fisika FTIRS
2. Bapak Bagus Tris Atmaja, S.T., M.T., Ph.D selaku dosen pembimbing Tugas Akhir
3. Kedua orang tua yang sudah membantu dan memberikan semangat untuk terus berjuang menyelesaikan Tugas Akhir
4. Rekan-rekan TA-wan Vibrastic Lab yang sudah membantu pengerjaan Tugas Akhir
5. Rekan-rekan asisten Vibrastic Lab yang sudah memberi dukungan dan support

Serta pihak-pihak lain yang tidak dapat disebutkan satu-persatu. Semoga laporan tugas akhir ini dapat dipergunakan dengan sebaik-baiknya.

Surabaya, 15 Juni 2022

Bagus Adhi Herlambang



*Halaman ini sengaja dikosongkan*

## DAFTAR ISI

HALAMAN JUDUL.....	i
COVER PAGE.....	iii
PERNYATAAN BEBAS PLAGIASI .....	v
LEMBAR PENGESAHAN .....	viii
LEMBAR PENGESAHAN .....	x
ABSTRAK .....	xii
ABSTRACT.....	xiv
KATA PENGANTAR .....	xvi
DAFTAR ISI.....	xviii
DAFTAR GAMBAR .....	xx
DAFTAR TABEL.....	xxi
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang .....	1
1.2 Rumusan Masalah .....	3
1.3 Tujuan.....	3
1.4 Batasan Masalah.....	3
1.5 Sistematika Laporan .....	3
BAB II TINJAUAN PUSTAKA DAN SASAR TEORI .....	4
2.1 Condition Monitoring .....	4
2.2 Anomalous Sound Detection (ASD).....	4
2.3 Short Time Fourier Transform (STFT) .....	5
2.4 MobileNet V2.....	6
2.5 Auto Encoder.....	7
2.6 Bidirectional Generative Adversarial Network (BiGAN).....	8
2.7 Domain Generalisasi .....	8
2.8 Receiver Operating Characteristic (ROC).....	9

2.9	<i>Area Under the Curve (AUC)</i> .....	10
BAB III METODOLOGI PENELITIAN .....		11
3.1	Studi literatur.....	11
3.2	Pengumpulan Dataset.....	11
3.3	Persiapan <i>Training Data</i> .....	12
3.4	Ekstraksi Fitur .....	12
3.5	Pembuatan Model <i>Deep Learning</i> .....	13
3.6	Pelaksanaan <i>Training Data</i> .....	13
3.7	Pelaksanaan <i>Testing Data</i> .....	13
BAB IV HASIL DAN PEMBAHASAN .....		16
4.1	Sinyal Suara Mesin .....	16
4.2	<i>Mel Spectrogram</i> .....	17
4.3	Suara Mesin Normal dan Anomali.....	18
4.4	Hasil <i>Training</i> dan <i>Testing</i> .....	18
4.5	Analisa Hasil .....	25
BAB V KESIMPULAN DAN SARAN .....		26
5.1	Kesimpulan .....	26
5.2	Saran.....	26
DAFTAR PUSTAKA .....		28
LAMPIRAN.....		xxxi
BIODATA PENULIS .....		xxxiii

## DAFTAR GAMBAR

<b>Gambar 2.1</b> Overview Sistem Anomalous Sound Detection (Kawaguchi, et al., 2021).....	5
<b>Gambar 2.2</b> Plot Grafik STFT (Librosa, 2022). ....	6
<b>Gambar 2.3</b> Convolution Layer. (a) <i>Standard Convolution Filters</i> , (b) <i>Depthwise Convolutional Filters</i> , (c) <i>Pointwise Convolution</i> . ( Howard, et al., 2017).....	7
<b>Gambar 2.4</b> Arsitektur <i>auto encoder</i> (Koizumi, et al., 2018).....	7
<b>Gambar 2.5</b> Arsitektur BiGAN (Donahue, Darrell, & Krähenbühl, 2017). ....	8
<b>Gambar 2.6</b> Ilustrasi Domain Generalisasi (Chan, Zhang, Cheng, & Shoubo, 2019).....	9
<b>Gambar 2.7</b> Grafik <i>Receiver Operating Characteristic</i> (Obuchowski, 2005) .....	9
<b>Gambar 2.8</b> Nilai AUC pada Grafik ROC (Zou, et al., 2007).....	10
<b>Gambar 3.1</b> Diagram Alir Penelitian.....	11
<b>Gambar 4.1</b> Plot grafik suara mesin normal (a) dan anomali (b) .....	16
<b>Gambar 4.2</b> Grafik DFT suara mesin normal (a) dan anomali (b) .....	17
<b>Gambar 4.3</b> Plot grafik <i>mel-spectrogram</i> suara mesin normal (a) dan anomali (b).....	17
<b>Gambar 4.4</b> Plot grafik <i>log mel-spectrogram</i> suara mesin gearbox normal (a) dan anomali (b).....	17
<b>Gambar 4.5</b> Perbedaan suara mesin gearbox (a) normal dan (b) anomali berdasarkan grafik <i>log mel-spectrogram</i> .....	18
<b>Gambar 4.6</b> Grafik hasil (a) AUC source, (b) AUC target, (c) pAUC menggunakan metode MobileNet V2.....	19
<b>Gambar 4.7</b> Grafik hasil (a) AUC source, (b) AUC target, (c) pAUC menggunakan metode Auto Encoder.....	21
<b>Gambar 4.8</b> Grafik hasil (a) AUC source, (b) AUC target, (c) pAUC menggunakan metode BiGAN .....	23
<b>Gambar 4.9</b> Perbandingan nilai AUC dan pAUC dari ketiga metode.....	25

## DAFTAR TABEL

<b>Tabel 3.1.</b> <i>Overview</i> Susunan Dataset.....	12
<b>Tabel 4.1</b> Hasil menggunakan metode MobileNet V2.....	20
<b>Tabel 4.2</b> Hasil menggunakan metode Auto Encoder.....	22
<b>Tabel 4.3</b> Hasil menggunakan metode BiGAN.....	24

*Halaman ini sengaja dikosongkan*

# BAB I

## PENDAHULUAN

### 1.1 Latar Belakang

Monitoring kondisi mesin merupakan kegiatan yang dilakukan untuk memastikan mesin berjalan sesuai dengan spesifikasi yang ada. Kegiatan monitoring kondisi mesin sangat berkaitan erat dengan kegiatan maintenance (Mohanty, 2015). Dengan adanya monitoring kondisi mesin, kesalahan dapat dideteksi secara dini, sehingga mengurangi terjadinya stop produksi yang berujung kerugian besar (Liang, Duan, Bennett, & Mba, 2020).

Salah satu pengembangan condition monitoring di era industri 4.0 adalah *Anomalous Sound Detection* (ASD). ASD merupakan metode untuk mengidentifikasi apakah suara yang dipancarkan dari objek (mesin) normal atau tidak normal. ASD adalah teknologi penting dalam pengembangan teknologi industri 4.0 yang menyangkut otomatisasi (Kawaguchi, et al., 2021). Anomali dalam suara yang dihasilkan oleh mesin dapat menunjukkan adanya indikasi kesalahan atau kerusakan, dengan melakukan deteksi anomali lebih awal dapat menghindari serangkaian masalah terutama dalam hal pemeliharaan prediktif. Deteksi Anomali dapat dikategorikan sebagai *supervised learning*, *unsupervised learning*, dan *semi-supervised learning*. Metode *supervised learning* merupakan salah satu metode *deep learning* yang mengharuskan seluruh kumpulan data target pelatihan diberi label "normal" atau "abnormal" dan metode ini pada dasarnya dilakukan pada klasifikasi biner maupun *multi classification*. Pada metode *semi-supervised learning* target label yang akan dilakukan klasifikasi tidak mencakup keseluruhan data, melainkan hanya Sebagian data saja, dalam metode ini, model akan mempelajari seperti apa data "normal" dan "abnormal". Metode *unsupervised learning* melibatkan data target yang tidak berlabel. Dalam teknik ini, model akan mempelajari data mana yang "normal" dan "abnormal" tanpa mengetahui kondisi dari data tersebut pada proses pelatihan (Nunez, 2021).

ASD merupakan deteksi anomali berbasis suara yang fleksibel dan dapat mengurangi biaya suatu perusahaan dalam hal monitoring kondisi mesin (*machine condition monitoring*). ASD dilakukan dengan mengumpulkan data berupa suara mesin dengan cara mendekatkan mikrofon ke mesin. Data tersebut kemudian diolah dengan menggunakan *deep learning* untuk mendeteksi adanya anomali. Hal tersebut dapat

menghindari kerugian besar yang disebabkan oleh kegagalan serius dengan menemukan kesalahan awal mesin dan melakukan perawatan secara efektif (Wang, et al., 2021).

Model klasifikasi biner *unsupervised* cocok untuk deteksi anomali. Pada saat mesin sedang bekerja, sangat sulit untuk mengumpulkan data berupa suara mesin *abnormal* di industri sebenarnya. Pada proses pelatihan, seluruhnya menggunakan data normal. Hal tersebut membuat metode *unsupervised learning* lebih mudah untuk digunakan dibandingkan dengan metode *supervised learning* (Wang, et al., 2021). Pada model *unsupervised* akan mempelajari karakteristik penting dari suara normal sehingga menemukan subruang di mana sampel normal berada, kemudian suara di luar subruang dinilai sebagai anomali dengan mengadopsi metode Auto Encoder sebagai anomali detector. Model dilatih dengan kesalahan rekonstruksi pada sampel normal, dan anomali skor diturunkan dari kesalahan rekonstruksi tersebut (Wilinghoff, 2020). Metode lain yang digunakan adalah MobileNet V2. Metode MobileNet V2 merupakan pengembangan dari metode MobileNet V1 yang menggunakan pendekatan arsitektur *convolutional neural networks* (CNN) dan sangat cocok digunakan untuk klasifikasi (Dai, Dai, Hirota, & Jia, 2020). *Generative adversarial networks* (GAN) juga dapat digunakan untuk deteksi anomaly pada suara mesin. Secara umum, GAN merupakan model yang memiliki dua neural networks, yaitu *generative* sebagai generator dan *adversarial* sebagai diskriminator. Generator bertujuan untuk menangkap distribusi data, sedangkan *discriminator* bekerja sebagai pendeteksi sampel yang ada merupakan sampel yang berasal dari input (*real*) atau hasil dari generator (*fake*) (Di Mattia, Galeone, De Simoni, & Ghelf, 2021).

Pada tugas akhir ini akan berfokus pada pengembangan metode ASD yang terbaru yaitu *bidirectional generative adversarial networks* (BiGAN) (Zenati, Foo, Lecouat, Manek, & Chandrasekhar, 2018). BiGAN merupakan pengembangan dari metode GAN yang tidak hanya melakukan *generate* data dari *latent space*, melainkan juga melakukan inverse dan pemetaan data input ke *latent space* (Donahue, Darrell, & Krähenbühl, 2017). Untuk menjalankan ketiga model yang digunakan, diperlukan *acoustic feature* sebagai *extractor* yang mengubah data berupa suara ekstensi wav ke dalam bentuk array data (Koizumi, Saito, Uematsu, & Harada, 2017). *Acoustic feature* yang digunakan banyak digunakan adalah *mel spectrogram* (Kawaguchi, et al., 2021). Mengembangkan metode *bidirectional generative adversarial networks* (BiGAN) untuk deteksi suara mesin normal dan abnormal memiliki potensi yang besar khususnya di bidang industri. Oleh karena itu



disusun Tugas Akhir untuk mendeteksi anomali suara mesin normal dan abnormal dengan metode *supervised* dan *unsupervised learning*.

## **1.2 Rumusan Masalah**

Berdasarkan latar belakang di atas, maka rumusan masalah pada penelitian ini adalah bagaimana metode MobileNet V2, Auto Encoder, dan *bidirectional generative adversarial networks* (BiGAN) yang paling tepat untuk deteksi anomaly suara mesin normal dan abnormal.

## **1.3 Tujuan**

Tujuan dilaksanakan penelitian ini adalah untuk menganalisis metode terbaik antara MobileNet V2, Auto Encoder, dan *bidirectional generative adversarial networks* (BiGAN) untuk deteksi anomali suara mesin normal dan abnormal

## **1.4 Batasan Masalah**

Batasan masalah pada penelitian ini adalah:

- a) Masing-masing metode menggunakan jumlah parameter training yang sama
- b) Penelitian ini tidak mendeteksi jenis kerusakan mesin yang dialami, melainkan hanya mendeteksi apakah mesin tersebut normal atau abnormal

## **1.5 Sistematika Laporan**

Laporan ini terdiri dari 5 bab. Pada bab 1 menjelaskan latar belakang, rumusan masalah, tujuan dan batasan masalah. Bab 2 menjelaskan tentang studi pustaka serta dasar teori yang menjadi landasan pada penelitian ini. Pada bab 3 menjelaskan metodologi penelitian. Bab 4 menjelaskan Analisa hasil dan pembahasan pada penelitian. Kemudian pada bab 5 membahas mengenai kesimpulan dan saran yang ada pada penelitian ini.

## **BAB II**

### **TINJAUAN PUSTAKA DAN SASAR TEORI**

#### **2.1 *Condition Monitoring***

Condition monitoring adalah proses pemantauan kondisi tertentu dalam mesin (seperti getaran, suhu, dll) untuk mengidentifikasi perubahan yang dapat menunjukkan kesalahan yang berkembang. Condition monitoring adalah bagian utama dari *predictive maintenance* karena penerapan pemantauan kondisi memungkinkan pemeliharaan terjadwal dan tindakan pencegahan diambil untuk mencegah kegagalan lebih lanjut dan kemungkinan adanya downtime yang tidak direncanakan di kemudian hari (Mohanty, 2015).


Condition Monitoring merupakan evolusi dari predictive maintenance. Predictive maintenance telah membuat kemajuan besar selama beberapa dekade terakhir. Saat ini, telah ditangani sebagai salah satu solusi paling inovatif untuk mengantisipasi kegagalan mesin dan digunakan oleh berbagai sektor industri. Predictive maintenance dapat diterapkan pada sektor industri besar karena dapat mencegah terjadinya breakdown sehingga memberikan keuntungan karena mengurangi biaya kegagalan yang mana harus mengganti komponen yang rusak. Oleh karena itu, hal ini dilakukan sebagai investasi dalam peralatan pengukuran dan sistem analisis (Carlos, et al., 2020).

#### **2.2 *Anomalous Sound Detection (ASD)***

*Anomalous sound detection (ASD)* merupakan metode untuk mengidentifikasi apakah suara yang dipancarkan dari objek (mesin) normal atau tidak normal. ASD adalah teknologi penting dalam pengembangan teknologi industri 4.0 yang menyangkut otomatisasi (Kawaguchi, et al., 2021). ASD merupakan deteksi anomali berbasis suara yang fleksibel dan dapat mengurangi biaya suatu perusahaan dalam hal monitoring kondisi mesin (*machine condition monitoring*). ASD dilakukan dengan mendekatkan mikrofon ke mesin yang berbeda untuk mendeteksi adanya anomali. Hal tersebut dapat digunakan untuk menghindari kerugian besar dengan menemukan kerusakan awal mesin (Wang, et al., 2021).

ASD digunakan untuk memprediksi perilaku abnormal dibandingkan dengan perilaku normal yang diamati setelah menyiapkan sistem. Setelah mendeteksi anomali,

pengklasifikasi mencoba mengidentifikasi kesalahan sistem berdasarkan kelas kegagalan yang telah ditentukan (Henze, et al., 2019).




**Gambar 2.1** Overview Sistem Anomalous Sound Detection (Kawaguchi, et al., 2021).

### 2.3 Short Time Fourier Transform (STFT)

*Short Time Fourier Transform* merupakan penerapan dari *discrete fourier transform* (DFT) yang dilakukan secara berurutan pada sinyal audio diskrit. STFT merepresentasikan sinyal dalam domain waktu – frekuensi. Algoritma STFT adalah pengembangan dari FFT (*Fast Fourier Transform*). Sinyal akan dicuplik dalam waktu tertentu pada algoritma ini. Sinyal yang diterima akan diterjemahkan dalam domain frekuensi. Kemudian sinyal dicuplik selama  $t$  detik, sehingga sinyal tersebut akan diketahui posisinya dalam domain waktu dan frekuensi (Yani, et al., 2008)..

*Fast Fourier Transform* (FFT) merupakan algoritma yang digunakan untuk merepresentasikan sinyal dalam domain waktu diskrit dan domain frekuensi. Proses FFT yang dilakukan berulang-ulang secara berurutan pada sinyal suara masukan ini disebut STFT. Metode overlap STFT digunakan agar hasil perubahan spectrum lebih halus yaitu dengan mengatur jarak antara frame FFT pertama dengan frame FFT berikutnya dengan *hop size* (Sari, 2019).




**Gambar 2.2** Plot Grafik STFT (Librosa, 2022).


## 2.4 MobileNet V2

MobileNet V2 adalah *convolutional neural network* yang memiliki kedalaman 53 lapisan. MobileNet V2 merupakan pengembangan dari arsitektur *deep learning*. Pada tahun 2017, MobileNet V2 diciptakan oleh Google, MobileNet V2 mempunyai layer khusus yang disebut dengan *depthwise separable convolution*. Layer *depthwise separable convolution* ini digunakan untuk mereduksi kompleksitas dan lebih sedikit parameter sehingga menghasilkan model yang lebih ukurannya. Perkembangan lebih lanjut dari MobileNet adalah MobileNet V2. Pada MobileNet V2, dua fitur terbarunya adalah linear bottleneck pada setiap layer dan koneksi shortcut antara bottlenecks (Arunraj, et al., 2017).


MobileNet didasarkan pada arsitektur ramping yang menggunakan konvolusi yang dapat dipisahkan secara mendalam untuk membangun bobot yang ringan *deep neural network*. Model MobileNet didasarkan pada *depthwise separable convolution* yang merupakan bentuk konvolusi terfaktor yang memfaktorkan konvolusi standar menjadi *depthwise convolution* dan konvolusi  $1 \times 1$  disebut *pointwise convolution*. Untuk MobileNet, konvolusi mendalam menerapkan filter tunggal ke setiap saluran input. *Pointwise convolution* kemudian menerapkan konvolusi  $1 \times 1$  untuk menggabungkan hasil *depthwise convolution*. Konvolusi standar memfilter dan menggabungkan input menjadi satu set output baru dalam satu langkah. *Depthwise separable convolution* membagi ini menjadi dua lapisan, lapisan terpisah untuk penyaringan dan yang terpisah lapisan untuk menggabungkan. Gambar 2.8 menunjukkan standard konvolusi Gambar 2.8(a) kemudian difaktorkan menjadi *depthwise convolution* pada Gambar 2.8(b) dan *pointwise convolution* pada Gambar 2.8(c) (Howard, et al., 2017).



(a) *Standard Convolution Filters*



(b) *Depthwise Convolutional Filters*




(c) *Pointwise Convolution*

**Gambar 2.3** Convolution Layer. (a) *Standard Convolution Filters*, (b) *Depthwise Convolutional Filters*, (c) *Pointwise Convolution*. (Howard, et al., 2017)

## 2.5 Auto Encoder

Auto encoder adalah sebuah jaringan syaraf tiruan yang digunakan untuk mempelajari data yang tidak berlabel (unsupervised learning). Autoencoder memiliki dua bagian utama yaitu encoder yang memetakan input ke dalam kode, dan decoder yang memetakan kode ke rekonstruksi input (Kramer, 1991).

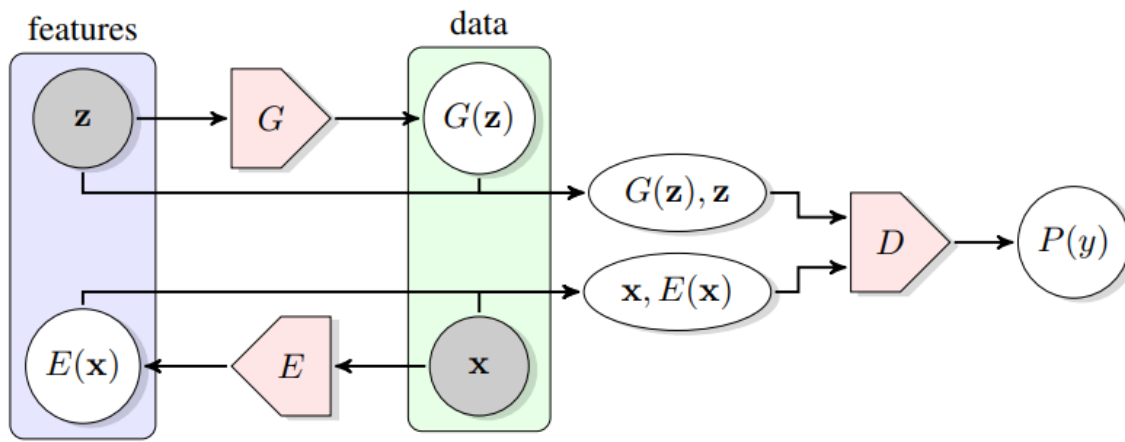


**Gambar 2.4** Arsitektur *auto encoder* (Koizumi, et al., 2018).

Ide *Auto Encoder* telah populer selama beberapa dekade. Pengaplikasian pertama dimulai pada 1980-an. Aplikasi yang paling tradisional adalah *dimensionality reduction* atau *feature learning*, tetapi konsep tersebut menjadi banyak digunakan untuk mempelajari model data generative. Beberapa AI paling kuat di tahun 2010-an melibatkan *auto encoder* yang ditumpuk di dalam *deep neural network* (Liu & Wu, 2018).

## 2.6 Bidirectional Generative Adversarial Network (BiGAN)

BiGAN merupakan pengembangan dari metode GAN yang tidak hanya melakukan *generate* data dari *latent space*, melainkan juga melakukan inverse dan pemetaan data input ke *latent space*. Secara umum BiGAN serupa dengan GAN yang memiliki dua *neural network* utama yaitu *generator* ( $G$ ) dan *discriminator* ( $D$ ). Perbedaan jelas antara GAN dengan BiGAN yaitu pada *generator* ( $G$ ) terdapat *encoder* ( $E$ ) yang bertugas untuk memetakan data ( $x$ ) ke dalam *latent space* ( $z$ ). Pada bagian *discriminator* BiGAN tidak hanya menerima data dari input ( $x$ ) dan hasil *generator*  $G(z)$ , melainkan juga data yang berasal dari *latent space* ( $z$ ) dan  $E(x)$  (Donahue, Darrell, & Krähenbühl, 2017).

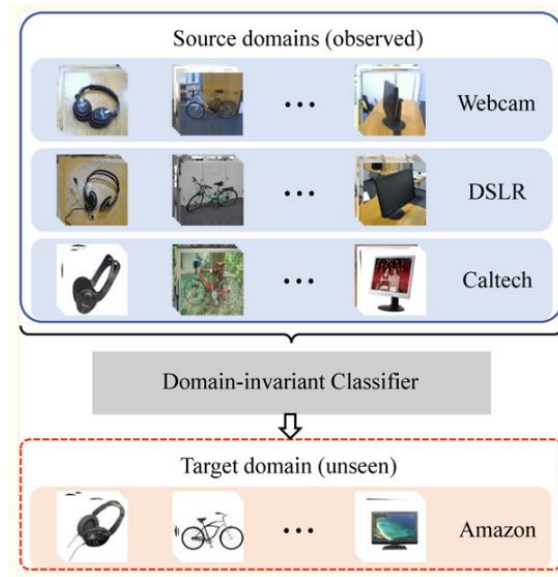


**Gambar 2.5** Arsitektur BiGAN (Donahue, Darrell, & Krähenbühl, 2017).

Metode BiGAN dinilai memiliki hasil yang lebih baik dibandingkan dengan metode GAN konvensional terutama pada deteksi anomali. Metode ini memiliki hasil yang baik ketika diimplementasikan menggunakan data gambar untuk mendeteksi anomaly pada gambar (Zenati, Foo, Lecouat, Manek, & Chandrasekhar, 2018).

## 2.7 Domain Generalisasi

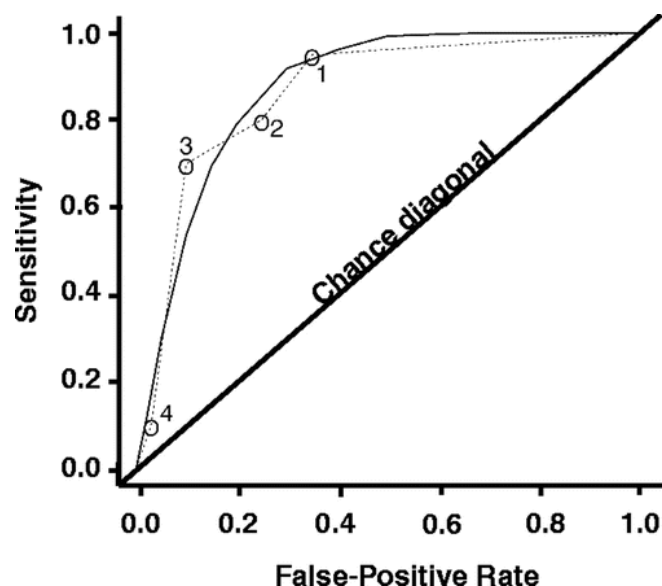
Domain generalisasi merupakan suatu metode yang bertujuan untuk mengenali informasi pada domain sumber (*source domain*) serta dilakukan generalisasi untuk mengetahui data yang terdapat pada domain yang berbeda *source domain* dan *target domain* (Chan, Zhang, Cheng, & Shoubo, 2019).



**Gambar 2.6** Ilustrasi Domain Generalisasi (Chan, Zhang, Cheng, & Shoubo, 2019)

## 2.8 Receiver Operating Characteristic (ROC)

Receiver Operating Characteristic (ROC) merupakan suatu garis terdapat pada kurva yang merepresentasikan hubungan antara sensitifitas dan spesifisitas (Kusmantoro, 2018). Kurva ROC terdiri dari plot false positive rate (FPR) atau  $1 - \text{spesifisitas}$  pada sumbu horizontal, dan true positive rate (FPR) atau sensitifitas pada sumbu vertikal. Setiap titik pada kurva mewakili nilai sensitifitas dan spesifisitas berdasarkan threshold yang ditentukan. Gabungan antara setiap titik tersebut disebut dengan garis ROC (Obuchowski, 2005).




**Gambar 2.7** Grafik Receiver Operating Characteristic (Obuchowski, 2005)

Kurva ROC dimulai dari koordinat (0,0) dan berakhir pada koordinat (1,1). Perbedaan nilai *threshold* akan mengakibatkan nilai sensitifitas dan spesifisitas yang

berbeda dan membentuk kurva. Setelah mendapatkan kurva ROC, nilai AUC dapat ditentukan dengan menghitung besar nilai di bawah kurva ROC (Obuchowski, 2005).

## 2.9 Area Under the Curve (AUC)

Area under the curve (AUC) merupakan luas area yang terdapat di bawah kurva ROC. Nilai AUC digunakan sebagai indicator akurasi suatu model. Nilai AUC dinilai lebih efektif karena menggabungkan antara nilai sensitivitas dengan spesifisitas (Zou, et al., 2007).



**Gambar 2.8** Nilai AUC pada Grafik ROC (Zou, et al., 2007)

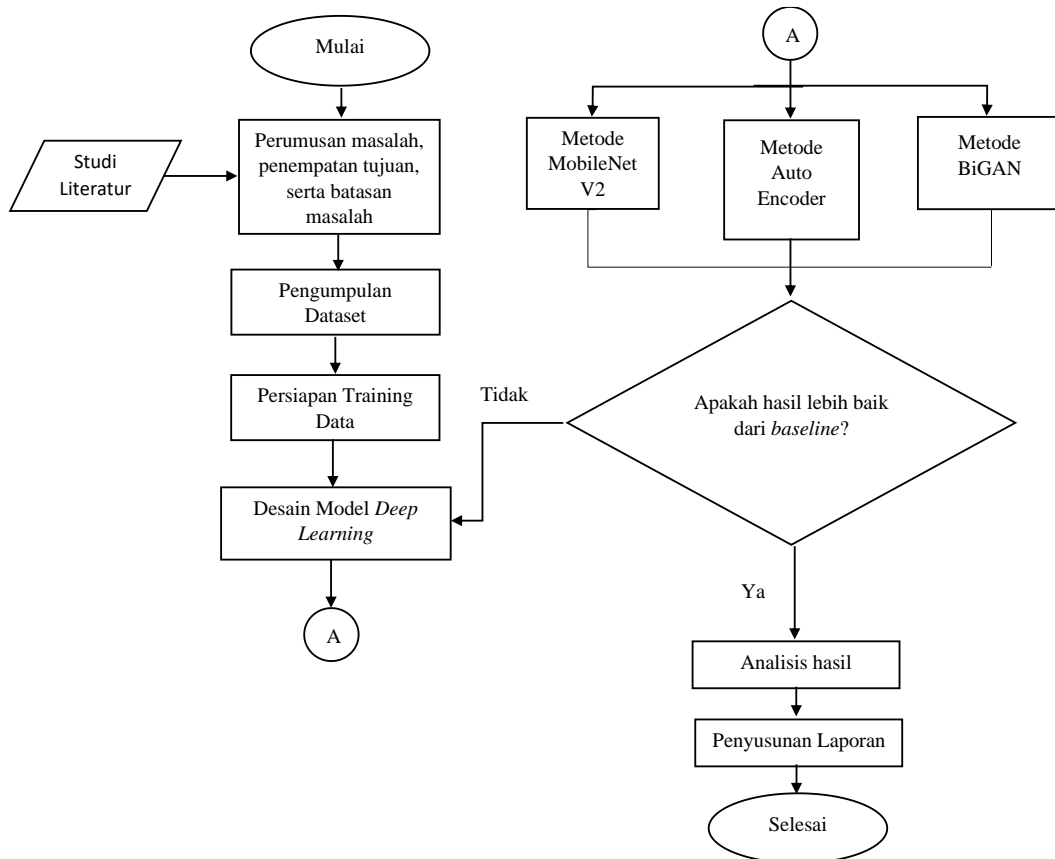
Berdasarkan Gambar 2.12 terdapat 3 garis pada kurva ROC. Nilai AUC pada garis A diketahui bernilai 1, nilai AUC pada garis C bernilai 0,5, sedangkan pada garis B nilai AUC adalah 0,85. Apabila nilai AUC berada  $< 0,5$  maka hasil model yang didapat belum termasuk ke dalam kriteria baik (Zou, et al., 2007).



## BAB III

### METODOLOGI PENELITIAN

Dalam tugas akhir ini terdapat beberapa langkah-langkah penelitian yang akan dilakukan pada pengerjaan tugas akhir ini. Berikut penjelasan dari setiap langkah-langkah yang akan dikerjakan dalam pengerjaan tugas akhir ini pada Gambar 3.1.



**Gambar 3.1** Diagram Alir Penelitian

#### 3.1 Studi literatur

Pada penelitian kali ini, studi literatur dilakukan sebagai Langkah awal dalam mengumpulkan teori-teori penunjang penelitian. Studi literatur dilakukan untuk mencari teori mengenai MobileNet V2, Auto Encoder, dan *bidirectional generative adversarial networks* (BiGAN). Literatur yang dicari juga dijadikan acuan peneliti dalam menentukan hipotesis pada penelitian kali ini. Dari hasil studi literatur tersebut didapatkan 3 metode dalam melakukan penelitian ini yaitu MobileNet V2, Auto Encoder, dan *bidirectional generative adversarial networks* (BiGAN).

#### 3.2 Pengumpulan Dataset

Data yang digunakan pada penelitian tugas akhir kali ini merupakan data sekunder yang disediakan oleh *Detection and Classification of Acoustic Scenes and Events* (DCASE

2021) Task 2: *Unsupervised Anomalous Sound Detection for Machine Condition Monitoring under Domain Shifted Condition*. Data yang digunakan pada training merupakan data kondisi mesin normal. Data yang diperoleh terdiri dari 7 tipe mesin antara lain pump, gearbox, valve, fan, slide rail, toy train, dan toy car. Dataset berupa suara rekaman masing-masing mesin. Setiap rekaman adalah audio berdurasi 10 detik yang mencakup suara pengoperasian mesin dan kebisingan lingkungan. Pengambilan sampling rate semua sinyal adalah 16 kHz. Suara mesin bercampur dengan kebisingan lingkungan, dan hanya rekaman bising yang tersedia sebagai data pelatihan/pengujian. Pada data *training* terdiri dari suara mesin normal, sedangkan untuk data *testing* terdiri dari data mesin normal dan abnormal (Kawaguchi, et al., 2021).

### 3.3 Persiapan Training Data

Setelah data sekunder dikumpulkan, selanjutnya data disusun berdasarkan 3 metode yang sudah ditentukan. Berikut merupakan setup direktori pada penelitian Tugas Akhir ini. Dataset terdiri dari *development dataset*. Pada bagian ini terdiri dari 3 *section* untuk setiap mesin (*section 00*, *section 01*, *section 02*). Untuk setiap *section*, dataset ini menyediakan 1.000 klip suara normal dalam *source domain* untuk *training*, tiga klip suara normal dalam *target domain* untuk *training*, sekitar 100 klip suara normal dan abnormal di *source domain* untuk *testing*, dan sekitar 100 klip masing-masing suara normal dan abnormal dalam *target domain* untuk *testing*.

**Tabel 3.1.** Overview Susunan Dataset

		Direktori	source	target	kondisi	
					normal	abnormal
DCASE (section 00,01,02)	Training	train	2970	30	3000	
	Testing	source_test	300		150	150
		target_test		300	150	150

### 3.4 Ekstraksi Fitur

Sinyal audio berdurasi 10 detik pada awalnya dilakukan ekstraksi fitur dengan menggunakan STFT, yaitu sinyal audio dibagi menjadi frame-frame yang sesuai dengan panjang dari sinyal tersebut dan frekuensi samplingnya. Sinyal suara ditransformasikan ke dalam domain waktu – frekuensi dengan menggunakan algoritma STFT. Jarak antara frame awal dengan frame berikutnya yang akan diproses disebut dengan *hop size*.

Setelah dilakukan ekstraksi fitur menggunakan STFT, hasil fitur dari STFT kemudian ditransformasikan dalam bentuk *mel frequency scale*. Selanjutnya nilai logaritma dari *mel spectrogram* dihitung sehingga dihasilkan data array yang dapat dijadikan sebagai input pada proses *training* dan *testing* menggunakan metode MobileNet V2, Auto Encoder dan *Bidirectional Generative Adversarial Network* (BiGAN). Dimensi input yang digunakan adalah 64 x 128 dimana pada data *training* terdiri dari 1000 data tiap section dan pada data *testing* terdiri dari 100 data setiap section.

### 3.5 Pembuatan Model *Deep Learning*

Model *deep learning* yang digunakan pada penelitian kali ini adalah *Bidirectional Generative Adversarial Network* (BiGAN). Model tersebut akan dibandingkan dengan dua model *baseline* yaitu MobileNet V2 dan Auto Encoder. BiGAN merupakan bagian dari metode GAN yang efektif digunakan untuk deteksi anomali (Zenati, Foo, Lecouat, Manek, & Chandrasekhar, 2018).

### 3.6 Pelaksanaan *Training Data*

Pada penelitian ini proses *training* data dilakukan satu per satu, mulai dari metode MobileNet-V2, BiGAN, dan *Auto Encoder*. Proses *training* dilakukan menggunakan bahasa pemrograman python dengan menggunakan *framework* tensorflow. Proses *training* data dilakukan menggunakan dataset yang berasal dari data sekunder *Detection and Classification of Acoustic Scenes and Events* (DCASE 2021) Task 2: *Unsupervised Anomalous Sound Detection for Machine Condition Monitoring under Domain Shifted Condition*. Data tersebut sejatinya sudah memiliki label. Namun, pada proses *training* metode MobileNet V2 dan Auto Encoder (*baseline*) label target tidak digunakan (*unsupervised*), sedangkan untuk metode BiGAN label target digunakan pada saat proses *training* (*supervised*).

### 3.7 Pelaksanaan *Testing Data*

*Testing* data dilakukan untuk mengetahui keakuratan model *training* yang telah dibuat pada proses *training*. Hasil pengujian ditentukan berdasarkan *Area Under the Curve* (AUC) dan parsial-AUC (pAUC). pAUC adalah AUC yang dihitung dari sebagian kurva ROC di atas rentang minat yang telah ditentukan sebelumnya. AUC dan pAUC untuk masing-masing jenis mesin, bagian, dan domain didefinisikan sebagai:

$$AUC_{m,n,d} = \frac{1}{N_-N_+} \sum_{i=1}^{N_-} \sum_{j=1}^{N_+} H(B_{\theta,j,i}) \quad (2)$$

$$pAUC_{m,n,d} = \frac{1}{[pN_-]N_+} \sum_{i=1}^{[pN_-]} \sum_{j=1}^{N_+} H(B_{\theta,j,i}) \quad (3)$$

Dimana:

$$(B_{\theta,j,i}) = A_{\theta}(x_j^+) - A_{\theta}(x_i^-) \quad (4)$$

Alasan tambahan penggunaan pAUC didasarkan pada persyaratan praktis. Jika sistem ASD sering memberikan alarm *fals*, hal tersebut tidak bisa terus dipercaya. Oleh karena itu, penting untuk meningkatkan tingkat *true positive* di bawah kondisi FPR rendah. Di dalam penelitian tugas akhir ini penentuan nilai pAUC dilakukan dengan maksimal FPR = 0,1.

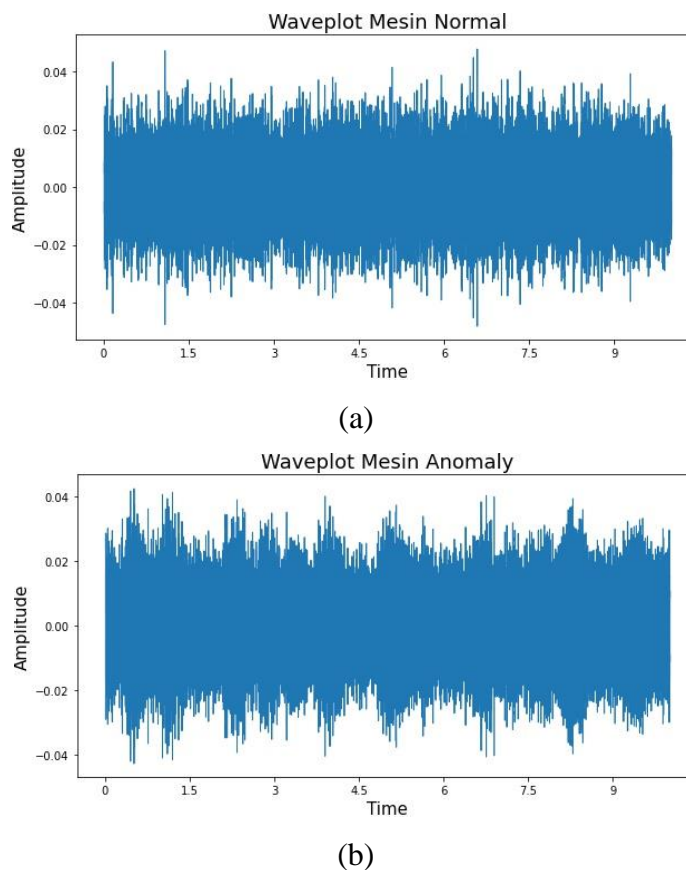
*Halaman ini sengaja dikosongkan*

## BAB IV

### HASIL DAN PEMBAHASAN

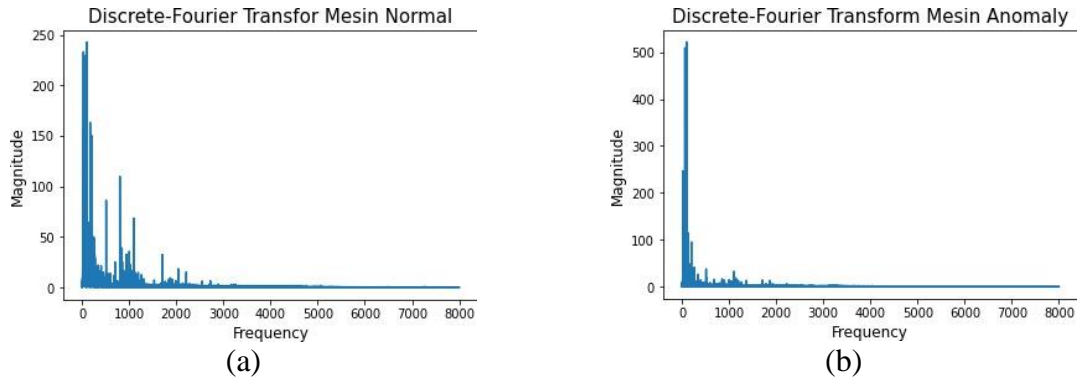
#### 4.1 Sinyal Suara Mesin

Pada penelitian ini, terdapat 7 macam mesin yang terdiri dari suara mesin normal dan abnormal. Suara mesin yang digunakan berjumlah 1000 data audio untuk *training* dan 200 data audio untuk *testing* pada masing masing mesin, tiap audio berdurasi tepat 10 detik. Berikut merupakan plot audio grafik amplitudo terhadap waktu pada mesin dengan keadaan normal dan anomali dengan mengambil *sample* satu file audio mesin fan dengan keadaan normal dan anomali.



**Gambar 4.1** Plot grafik suara mesin normal (a) dan anomali (b)


Pada Gambar 4.1, terlihat bahwa tidak terdapat perbedaan yang signifikan antara suara mesin normal dan anomali. Plot grafik *Discrete-fourier transforms* (DFT) dilakukan guna mengetahui perbedaan antara kondisi mesin normal dengan anomali, seperti yang terlihat pada Gambar 4.2. Pada suara mesin normal magnitudo pada grafik DFT lebih kecil apabila dibandingkan dengan suara mesin anomali pada frekuensi rendah.



**Gambar 4.2** Grafik DFT suara mesin normal (a) dan anomali (b)

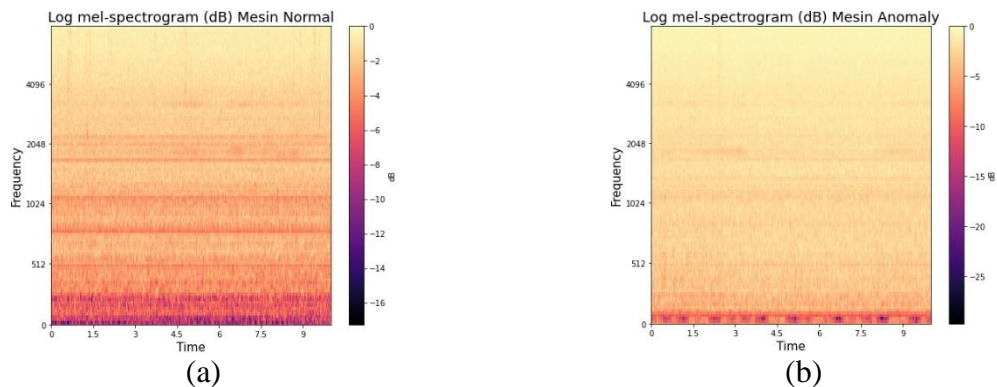
## 4.2 Mel Spectrogram

Sebelum dilakukan *training* menggunakan model *deep learning*. File audio yang ada pada data *training* dan *testing* terlebih dahulu dilakukan ekstraksi fitur untuk mengetahui informasi yang terdapat di dalam masing-masing sinyal audio yang ada. Ekstraksi fitur dilakukan menggunakan fitur *mel spectrogram*. Berikut merupakan plot grafik *mel spectrogram* pada *sample* audio mesin normal dan anomali pada mesin gearbox.



**Gambar 4.3** Plot grafik *mel-spectrogram* suara mesin normal (a) dan anomali (b)

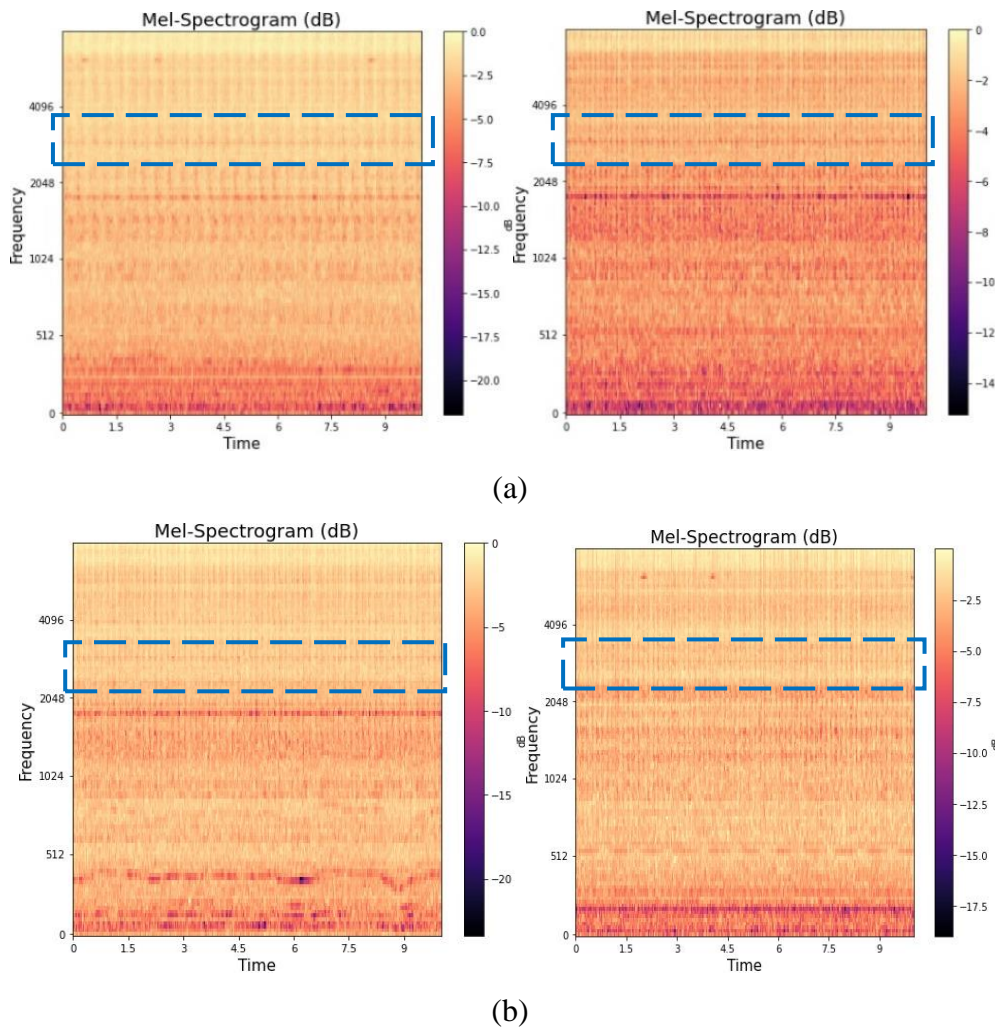
Setelah audio diekstrak menggunakan *mel-spectrogram*. Hasil keluaran dari ekstraksi fitur tersebut dikonversi menjadi *log mel-spectrogram* sehingga didapatkan plot grafik *log mel-spectrogram*.



**Gambar 4.0.4** Plot grafik *log mel-spectrogram* suara mesin gearbox normal (a) dan anomali (b)

### 4.3 Suara Mesin Normal dan Anomali

Setelah dilakukan ekstraksi fitur menggunakan *mel-spectrogram*. Sinyal suara yang dihasilkan dari masing-masing jenis mesin diamati perbedaan antara suara mesin normal dan anomali. Berikut merupakan beberapa contoh suara mesin normal dan anomali pada mesin gearbox yang disajikan pada grafik *log mel-spectrogram*.



**Gambar 4.5** Perbedaan suara mesin gearbox (a) normal dan (b) anomali berdasarkan grafik *log mel-spectrogram*

Berdasarkan grafik *log mel-spectrogram* terlihat bahwa pada mesin normal terdapat kenaikan nilai intensitas bunyi secara signifikan pada frekuensi antara 2048 sampai 4096 Hz, sedangkan pada suara mesin anomali tidak ada.

### 4.4 Hasil Training dan Testing


Data yang dihasilkan dari ekstraksi fitur menggunakan *mel-spectrogram*. Pada proses ini jumlah FFT yang digunakan sebanyak 1024, dengan *hop length* sebesar 512, jumlah *mels* adalah 64 dan jumlah *frames* adalah 128, dengan *sampling rate* sebesar 16 kHz. Sehingga dihasilkan input data array dengan dimensi 64 x 128. Dimana 1 file wav dibagi menjadi 32 data array. Sehingga jumlah data dan dimensi array adalah 32000 x 64 x 128




pada data *training*, dan 3200 x 64 x 128 pada data *testing*. Hasil *training* dan *testing* disajikan dalam bentuk *metric* AUC dan pAUC. Perhitungan nilai AUC dibagi menjadi domain *source* dan *target*. Setiap mesin dibagi menjadi 3 section yaitu section 00, 01, dan 02. Kemudian hasil AUC dari ketiga section tersebut dihitung nilai *arithmetic mean* dan *harmonic mean*. Pada perhitungan nilai pAUC domain *source* dan *target* tidak dibedakan.

#### 4.4.1 Hasil Metode MobileNet V2

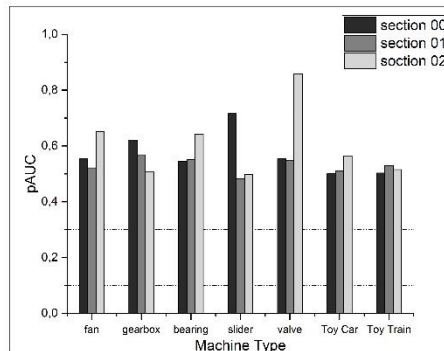
MobileNet V2 merupakan metode pada *baseline* DCASE 2022 *Challenge*. Berikut merupakan hasil yang didapat pada proses *training* dan *testing* disajikan dalam bentuk *metric* AUC dan pAUC. Hasil yang diperoleh dari metode MobileNet V2 memiliki kemampuan yang baik dalam deteksi anomaly pada mesin valve dengan nilai AUC sebesar 61,96 % dan pAUC sebesar 62,49 %. Sedangkan pada mesin Toy Train, metode ini kurang baik dalam melakukan deteksi anomaly dengan nilai AUC sebesar 51,55 % dan pAUC sebesar 51,56%.



(a)



(b)



(c)


**Gambar 4.6** Grafik hasil (a) AUC source, (b) AUC target, (c) pAUC menggunakan metode MobileNet V2

**Tabel 4.1** Hasil menggunakan metode MobileNet V2

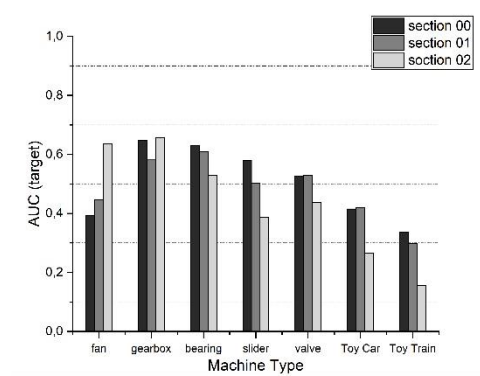
Mesin	Section	AUC		pAUC	
		Source	Target	Source	Target
Toy Car	0	47,40%	56,40%	49,96%	
	1	62,02%	56,38%	50,92%	
	2	74,19%	45,64%	56,51%	
	Arithmetic Mean	57,01%		52,46%	
	Harmonic Mean	55,52%		52,31%	
Toy Train	0	46,02%	49,41%	50,25%	
	1	71,96%	45,14%	52,97%	
	2	63,23%	44,34%	51,54%	
	Arithmetic Mean	53,35%		51,59%	
	Harmonic Mean	51,55%		51,56%	
Fan	0	71,07%	62,13%	55,40%	
	1	76,26%	35,12%	52,14%	
	2	67,29%	58,02%	65,14%	
	Arithmetic Mean	61,65%		57,56%	
	Harmonic Mean	57,78%		57,05%	
Gearbox	0	63,54%	67,02%	62,12%	
	1	66,68%	66,96%	56,85%	
	2	80,87%	43,15%	50,62%	
	Arithmetic Mean	64,70%		56,53%	
	Harmonic Mean	62,41%		56,13%	
Bearing	0	67,85%	60,17%	54,41%	
	1	59,67%	64,65%	55,09%	
	2	61,71%	60,55%	64,18%	
	Arithmetic Mean	62,43%		57,89%	
	Harmonic Mean	62,30%		57,57%	
Slider	0	87,15%	80,77%	71,57%	
	1	49,66%	32,07%	48,21%	
	2	72,70%	32,94%	49,69%	
	Arithmetic Mean	59,22%		56,49%	
	Harmonic Mean	50,30%		54,70%	
Valve	0	75,26%	43,60%	55,37%	
	1	54,78%	60,43%	54,69%	
	2	76,26%	78,74%	85,74%	
	Arithmetic Mean	64,85%		65,27%	
	Harmonic Mean	61,96%		62,49%	
All Machine	Arithmetic Mean	60,46%		56,83%	
	Harmonic Mean	57,00%		55,77%	

#### 4.4.2 Hasil Metode Auto Encoder (AE)


Auto Encoder merupakan metode yang juga digunakan dalam *baseline* DCASE 2022 *Challenge*. Auto Encoder memiliki dua bagian utama yaitu encoder yang memetakan input ke dalam kode, dan decoder yang memetakan kode ke rekonstruksi input (Kramer, 1991). Berikut merupakan hasil yang didapat pada proses *training* dan *testing* disajikan dalam bentuk *metric* AUC dan pAUC. Hasil yang diperoleh dari metode Auto Encoder memiliki kemampuan yang baik dalam deteksi anomali pada mesin gearbox dengan nilai AUC sebesar 65,64 % dan pAUC sebesar 58,50 %. Sedangkan pada mesin valve, metode ini kurang baik dalam melakukan deteksi anomali dengan nilai AUC sebesar 50,72 % dan pAUC sebesar 50,36%. Perbandingan nilai AUC dan pAUC tiap mesin dapat dilihat pada Gambar 4.7.



(a)



(b)



(c)

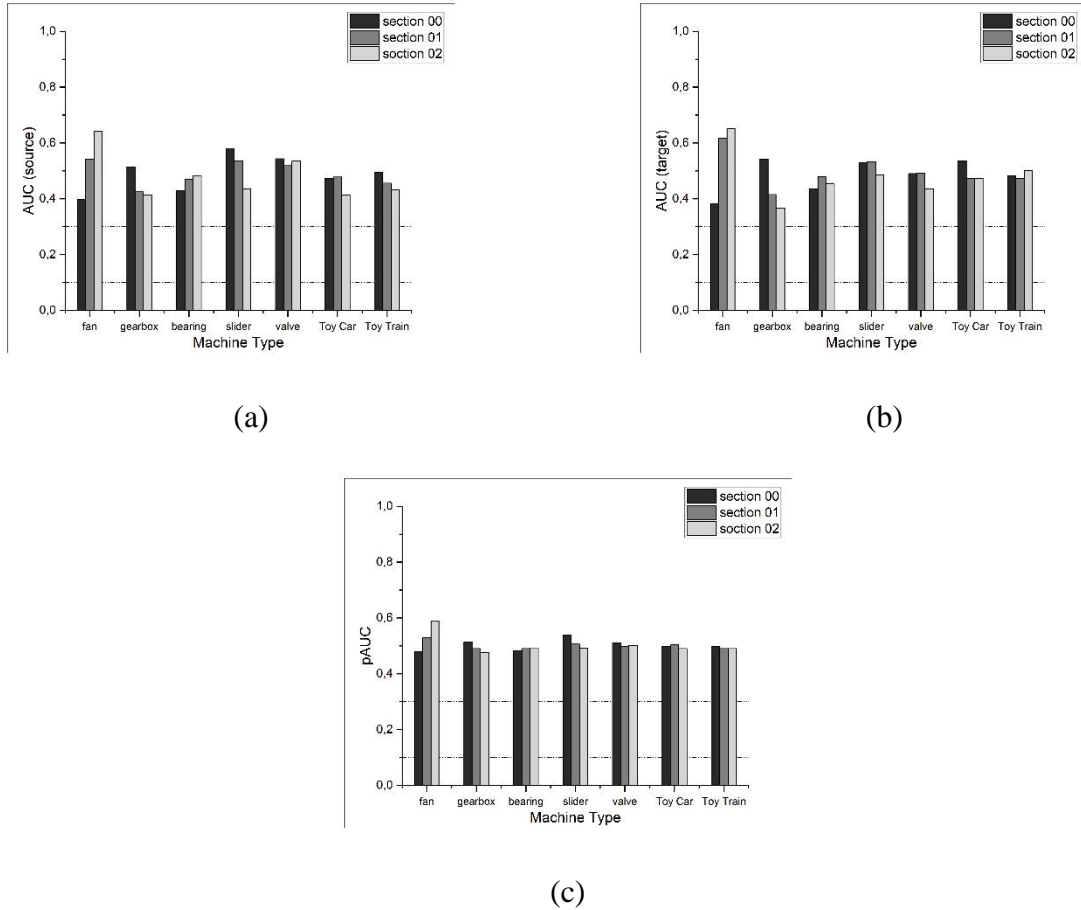
**Gambar 4.7** Grafik hasil (a) AUC source, (b) AUC target, (c) pAUC menggunakan metode Auto Encoder

**Tabel 4.2** Hasil menggunakan metode Auto Encoder

Mesin	Section	AUC		pAUC	
		Source	Target	Source	Target
Toy Car	0	86,42%	41,48%	51,31%	
	1	89,85%	41,93%	54,08%	
	2	98,84%	26,50%	52,96%	
	Arithmetic Mean	64,17%		52,78%	
	Harmonic Mean	50,63%		52,76%	
Toy Train	0	67,54%	33,68%	52,72%	
	1	79,32%	29,87%	50,64%	
	2	84,08%	15,52%	48,33%	
	Arithmetic Mean	51,67%		50,56%	
	Harmonic Mean	35,95%		50,50%	
Fan	0	84,69%	39,35%	59,95%	
	1	71,69%	44,74%	51,12%	
	2	80,54%	63,49%	62,88%	
	Arithmetic Mean	64,08%		57,98%	
	Harmonic Mean	59,00%		57,53%	
Gearbox	0	64,63%	64,79%	60,93%	
	1	67,66%	58,12%	53,74%	
	2	75,38%	65,57%	61,51%	
	Arithmetic Mean	66,03%		58,73%	
	Harmonic Mean	65,64%		58,50%	
Bearing	0	57,48%	63,07%	51,49%	
	1	71,03%	61,04%	55,85%	
	2	42,34%	52,91%	49,18%	
	Arithmetic Mean	57,98%		52,17%	
	Harmonic Mean	56,48%		52,03%	
Slider	0	81,92%	58,04%	61,65%	
	1	67,85%	50,30%	53,06%	
	2	86,66%	38,78%	53,44%	
	Arithmetic Mean	63,93%		56,05%	
	Harmonic Mean	59,18%		55,78%	
Valve	0	54,24%	52,73%	52,15%	
	1	50,45%	53,01%	49,78%	
	2	51,56%	43,84%	49,24%	
	Arithmetic Mean	50,97%		50,39%	
	Harmonic Mean	50,72%		50,36%	
All Machine	Arithmetic Mean	59,83%		54,10%	
	Harmonic Mean	52,21%		53,75%	

#### 4.4.3 Hasil Metode BiGAN

*Bidirectional generative adversarial network* (BiGAN) merupakan metode yang diajukan pada penelitian ini. Berikut merupakan hasil yang didapat pada proses *training* dan *testing* disajikan dalam bentuk *metric* AUC dan pAUC.



**Gambar 4.8** Grafik hasil (a) AUC source, (b) AUC target, (c) pAUC menggunakan metode BiGAN

Hasil yang didapat menggunakan metode BiGAN menunjukkan hasil yang lebih buruk dari kedua metode sebelumnya. Hal tersebut dikarenakan BiGAN kurang baik dalam mengenali data normal dan anomali menggunakan input ekstraksi fitur yang sama dengan *baseline*. Selain itu dataset yang digunakan merupakan data suara yang sulit dan kurang efektif apabila diaplikasikan pada model deteksi anomali lainnya seperti BiGAN (Kumari, Bedi, & Saini, 2022). Pada penelitian yang dilakukan oleh (Zenati, Foo, Lecouat, Manek, & Chandrasekhar, 2018) dan (Donahue, Darrell, & Krähenbühl, 2017), metode BiGAN bekerja dengan baik dengan menghasilkan nilai AUC dan pAUC yang baik. Kedua penelitian sebelumnya yang dilakukan menggunakan metode BiGAN menggunakan data berupa gambar, dimana perbedaan antara data normal dengan anomali terlihat signifikan.

Hal tersebut berbeda dengan dataset yang digunakan pada penelitian ini. Pada dataset DCASE 2022, sinyal suara normal dan anomali sangat sedikit sekali perbedaannya.

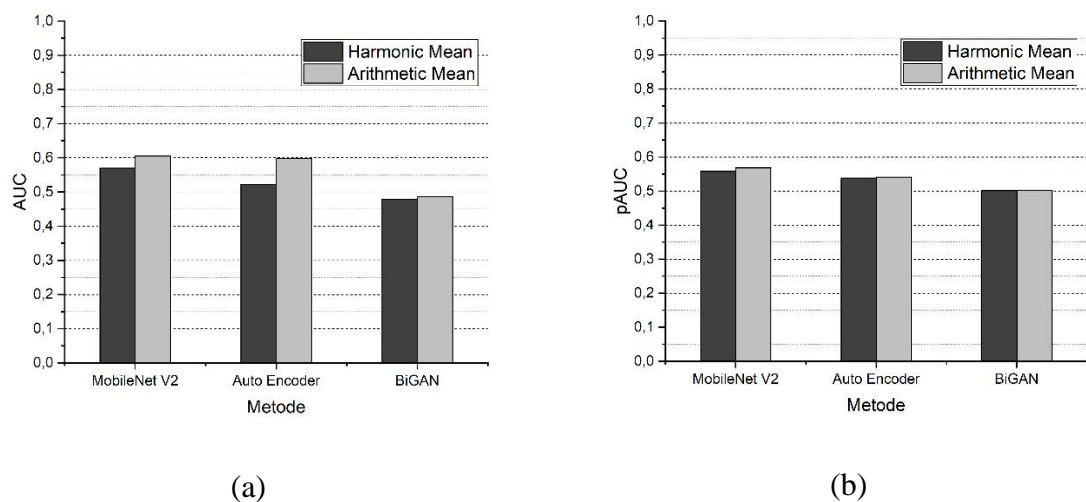
**Tabel 4.3** Hasil menggunakan metode BiGAN

Mesin	Section	AUC		pAUC	
		Source	Target	Source	Target
Toy Car	0	47,37%	53,61%	49,87%	
	1	47,77%	47,35%	50,35%	
	2	41,47%	47,27%	49,03%	
	Arithmetic Mean	47,47%		49,75%	
	Harmonic Mean	47,21%		49,73%	
Toy Train	0	49,47%	48,21%	49,70%	
	1	45,60%	47,38%	49,02%	
	2	43,20%	50,03%	49,02%	
	Arithmetic Mean	47,32%		49,24%	
	Harmonic Mean	47,20%		49,24%	
Fan	0	39,86%	38,34%	47,89%	
	1	54,25%	61,60%	52,81%	
	2	64,23%	65,05%	58,75%	
	Arithmetic Mean	53,89%		53,15%	
	Harmonic Mean	51,38%		52,74%	
Gearbox	0	51,38%	54,26%	51,30%	
	1	42,48%	41,48%	49,03%	
	2	41,26%	36,73%	47,55%	
	Arithmetic Mean	44,60%		49,29%	
	Harmonic Mean	43,79%		49,24%	
Bearing	0	43,04%	43,54%	48,26%	
	1	47,03%	47,97%	49,02%	
	2	48,32%	45,30%	49,31%	
	Arithmetic Mean	45,87%		48,86%	
	Harmonic Mean	45,77%		48,85%	
Slider	0	58,08%	53,03%	53,94%	
	1	53,66%	53,33%	50,60%	
	2	43,41%	48,61%	49,13%	
	Arithmetic Mean	51,69%		51,22%	
	Harmonic Mean	51,25%		51,12%	
Valve	0	54,33%	49,02%	51,04%	
	1	51,84%	49,12%	49,72%	
	2	53,43%	43,45%	50,16%	
	Arithmetic Mean	50,20%		50,31%	
	Harmonic Mean	49,92%		50,26%	
All Machine	Arithmetic Mean	48,72%		50,26%	
	Harmonic Mean	47,93%		50,14%	

#### 4.5 Analisa Hasil

Model *baseline* yang dijadikan sebagai acuan pada penelitian ini adalah MobileNet V2 dan Auto Encoder. Keduanya termasuk ke dalam metode *unsupervised learning* karena pada proses *training* data, informasi mengenai kondisi mesin normal dan anomali tidak diketahui. Metode *unsupervised learning* lebih cocok digunakan untuk deteksi anomali (Wang, et al., 2021). Metode yang menjadi keterbaruan pada penelitian ini adalah BiGAN. Metode BiGAN terbukti memiliki hasil yang baik dalam deteksi anomali (*anomaly detection*). Pada penelitian sebelumnya, BiGAN digunakan untuk deteksi anomali dengan menggunakan data input berupa gambar dan dikonversikan ke dalam array (Zenati, Foo, Lecouat, Manek, & Chandrasekhar, 2018) (Donahue, Darrell, & Krähenbühl, 2017). BiGAN yang digunakan pada penelitian ini menggunakan metode *supervised learning* karena pada proses *training* data, informasi mengenai kondisi mesin diketahui.

Hasil menunjukkan bahwa metode *supervised learning* menggunakan BiGAN memiliki hasil yang lebih buruk dari metode *unsupervised learning* menggunakan MobileNet V2 dan Auto Encoder. Penggunaan variasi *supervised* dan *unsupervised learning* tidak berpengaruh banyak terhadap hasil yang didapat. Hal tersebut karena kasus yang ada pada penelitian ini adalah *anomaly detection* yang hanya menggunakan data normal sebagai data pelatihan.



**Gambar 4.9** Perbandingan nilai AUC dan pAUC dari ketiga metode

## **BAB V**

### **KESIMPULAN DAN SARAN**

#### **5.1 Kesimpulan**

Pada penelitian ini didapat kesimpulan bahwa metode BiGAN bekerja kurang baik dalam deteksi anomali suara mesin normal dan abnormal. Hal tersebut dikarenakan dataset yang digunakan sangat sulit untuk dibedakan antara mesin normal dan abnormal. Penggunaan variasi metode *supervised* dan *unsupervised learning* tidak berpengaruh secara signifikan terhadap hasil yang diperoleh karena pada proses *training* data yang digunakan hanya satu macam saja yaitu data normal.

#### **5.2 Saran**

Saran untuk penelitian selanjutnya adalah variasi lebih ditekankan pada proses ekstraksi fitur. Penelitian selanjutnya juga dapat menggunakan dataset dari sumber lain sebagai tambahan agar hasil yang diperoleh lebih baik.



*Halaman ini sengaja dikosongkan*

## DAFTAR PUSTAKA

- Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., . . . Adam, H. (2017). MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Application. *arXiv:1704.04861 [cs.CV]*.
- Arunraj, N. S., Hable, R., Fernandes, M., Leidl, K., & Heigl, M. (2017). Comparison of Supervised, Semi-supervised and Unsupervised Learning Methods in Network Intrusion Detection System (NIDS) Application . *Anwendungen und Konzepte der Wirtschaftsinformatik*, 1.
- Bai, L. (2011). Electric Drive System with BLDC Motor. *International Conference on Electric Information and Control Engineering* (hal. 254). Kuala Lumpur: Universiti Malaya.
- Blanke, M. (1999). *Fault Tolerant Control Systems*. London: Adventure Workd Press.
- Carlos, J., Correa, J., A., A., & Guzman, L. (2020). *Mechanical Vibrations and Condition Monitoring*.
- Chan, L., Zhang, K., Cheng, Z., & Shoubo, H. (2019). Domain Generalization via Multidomain Discriminant Analysis. *HHS Author Manuscripts*.
- Cho, J. R. (2007). Braking Distance Prediction by Hydroplaning Analysis of 3-D Patterned Tire Model. *Journal of System Design and Dynamics*, 1(3), 398-409.
- Cui, G., & al., e. (2017). Slip Control of Electric Vehicle Based on Tire-Road Friction Coefficient Estimation. *Hindawi Mathematical Problems in Engineering*.
- Dai, W., Dai, Y., Hirota, K., & Jia, Z. (2020). A Flower Classification Approach with MobileNetV2and Transfer Learning. *The 9th International Symposium on Computational Intelligence and Industrial Applications*.
- Di Mattia, F., Galeone, P., De Simoni, M., & Ghelf, E. (2021). A Survey on GANs for Anomaly Detection. 1-16.
- Donahue, J., Darrell, T., & Krähenbühl, P. (2017). Adversarial Feature Learning. *ICLR 2017*.
- Errabelli, R. (2012). Fault-Tolerant Voltage Source Inverter for Permanent Magnet Drives. *IEEE Transactions on Power Electronics*, 27.
- Gao, Y. (2001). Electronic Braking System of EV and HEV--Integration of Regenerative Braking, Automatic Braking Force Control and ABS. *42 Volt Technology and Advanced Vehicle Electrical Systems*.
- Guo, J., Jian, X., & Lin, G. (2014). Performance Evaluation of an Anti-Lock Braking System for Electric Vehicles with a Fuzzy Sliding Mode Control. *Energies*, 7, 6459-6476.
- Henze, D., Gorishti, K., Bruegge, B., & Simen, J.-P. (2019). AudioForesight: A Process Model for Audio Predictive Maintenance in Industrial Environments. *18th IEEE International Conference On Machine Learning And Applications (ICMLA)*.

- Indriawati, K. (t.thn.). Robust Fuzzy Observer-based Fault Tolerant Tracking Control for Nonlinear Systems with Simultaneous Actuator and Sensor Faults: Application to a DC Series Motor Speed Drive. *Praise Worthy Prize*, 375-385.
- Kawaguchi, Y., Imoto, K., Koizumi, Y., Harada, N., Niizumi, D., & Dohi, K. (2021). Description and Discussion on DCASE 2021 Challenge Task 2 : Unsupervised. *DCASE 2021*.
- Koizumi, Y., Kawachi, Y., & Harada, N. (2018). Unsupervised Detection of Anomalous Sound based on Deep Learning and the Neyman-Pearson Lemma. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*.
- Koizumi, Y., Saito, S., Uematsu, H., & Harada, N. (2017). Optimizing Acoustic Feature Extractor for Anomalous Sound Detection Based on Neyman-Pearson Lemma. *25th European Signal Processing Conference (EUSIPCO)*, 1-5.
- Kramer, M. A. (1991). Nonlinear Principal Component Analysis Using Autoassociative Neural Networks. *AIChE Journal*.
- Kumari, P., Bedi, A. K., & Saini, M. (2022). Multimedia Datasets for Anomaly Detection: A Review.
- Kusmantoro, Z. N. (2018). Akurasi Uji Diagnostik Menggunakan Luasan Bawah Kurva ROC Smothed Empirical. *Program Studi Statistika, Departemen Matematika, Fakultas MIPA, UGM*.
- Liang, X., Duan, F., Bennett, I., & Mba, D. (2020). A Sparse Autoencoder-Based Unsupervised Scheme.
- Librosa. (2022). *Librosa - STFT*. Diambil kembali dari Librosa: <http://librosa.org/doc/main/generated/librosa.stft.html>
- Liu, Y., & Wu, L. (2018). High Performance Geological Disaster Recognition using Deep Learning. *Procedia Computer Science 139 (2018) 529–536*.
- Lubbers, K. (2014). Design and Analysis of a Model Based Low Level Slip Controller Based on a Hybrid Braking System. *Science in Systems and Control Delft University*.
- M., A. (t.thn.). PID Control. *Control Systems, Robotics, and Automation*, 2.
- Manias, S. (2017). *Power Electronics and Motor Drive Systems*. Athens: Academic Press.
- Mohanty, A. R. (2015, August 23). *Machinery Condition Monitoring: Principles and Practices*. Taylor & Francis Group. Dipetik August 23, 2021, dari <https://www.machinevision.global/post/apa-yang-dimaksud-condition-monitoring>
- Murali, T. (2017). Four Quadrant Operation and Control of Three Phase BLDC Motor. *International Conference on Circuits Power and Computing Technology*.
- Nunez, E. C. (2021). Anomalous Sound Detection with Machine Learning: A Systematic Review.
- Obuchowski, N. A. (2005). Fundamentals of Clinical Research for Radiologists. Dalam *ROC Analysis*. American Journal of Roentgenology.

- Offer, G. J. (2010). Comparative analysis of battery electric, hydrogen fuel cell, and hybrid vehicle in a future sustainable road transport system. *energy policy*, 38, 24-29.
- Saleh, A. (2014). Speed Control of Brushless DC Motor Based on Fractional Order PID Controller. *Internal Journal of Computer Applications*.
- Sari, K. D. (2019). Deteksi Onset Pada Sinyal Musik gamelan Berdasarkan Skala Mel dan Bark Menggunakan Elemen Neural Networks. *Master Tesis Institut Teknologi Sepuluh Nopember*.
- Shiosansi, R. (2008). Emissions Impacts and Benefits of Plug-in Hybrid Electric Vehicles and Vehicle-to-Grid Services. *Environmental Science Technology*, 1199-1204.
- Singh, C. P. (2012). State-space Based Simulink Modeling of BLDC Motor and its Speed Control Using Fuzzy PID Controller. *International Journal of Advances in Engineering Science and Technology*, 2, 359-369.
- Suganya, M. K. (2014). Simulation of Four Quadrant Operation of Three Phase BLDC Motor Using Fuzzy. *International Journal of Innovative Research in Science. Engineering, and Techology*, 3(1).
- Tashakori, A. (2011). Modeling of BLDC Motor with Ideal Back-EMF for Automotive Applications. *World Congress on Engineering*. London.
- Tur, O. (2007). An Introduction to Regenerative Braking of Electric Vehicles as Anti-Lock Braking System. *Proceedings of 2007 IEEE Intelligent Vehicles Symposium*, (hal. 13-15). Istanbul.
- Urquizo, A. (2011). *PID Controller*. Dipetik Januari 28, 2019, dari [https://en.wikipedia.org/wiki/PID\\_controller#/media/File:PID\\_en.svg](https://en.wikipedia.org/wiki/PID_controller#/media/File:PID_en.svg)
- Wang, Y., Zheng, Y., Zhang, Y., Xie, Y., Xu, S., Hu, Y., & He, L. (2021). Unsupervised Anomalous Sound Detection for Machine Condition Monitoring Using Classification-Based Methods. 1-7.
- Westbrook, M. H. (2005). *Development and future of battery, hybrid, and fuel-cell cars*. London: The Institution of Electrical Engineers.
- Wilkinghoff, K. (2020). *Anomalous Sound Detection With Look, Listen, and Learn Embeddings*. DCASE 202
- Yani, K., Rizal, A., & Prasetya, B. (2008). Analisis Kinerja Algoritma Short Time Fourier Transform (STFT) untuk Deteksi Sinyal Carrier frequency hopping Spread Spectrum (FHSS) CDMA. *Seminar Sistem Informasi Indonesia (SESINDO2008)*.
- Yedamale, P. (2003). *Brushless DC (BLDC) Motor Fundamentals*. Arizona: Microchip Technology.
- Zenati, H., Foo, C.-S., Lecouat, B., Manek, G., & Chandrasekhar, V. R. (2018). Efficient GAN-Based Anomaly Detection. *ICLR 2018*.
- Zou, K. H., O'Malley, A. J., & Mauri, L. (2007). Receiver-Operating Characteristic Analysis for Evaluating Diagnostic Tests and Predictive Models. 115.

## LAMPIRAN

### A. Sistem Pengereman Regenerative sebagai ABS

Gambar

### B. Quarter Car Model

Gambar

### C. Sistem Motor

Gambar

### D. Observer

Gambar

### E. Pemberian kesalahan pada aktuator

Gambar

### F. Kode Matlab

```
clc;
%% parameter
m = 425;
r = 325;
Af = 3.1;
Cr = 3;
v0 = 27.778;
freq_max = 20000;
h = 0.1;
nb_p = 4;
Ts_vect = 50e-6;
%% ss
A = [-9.9 0; 0 -9.9];
B = [66.667 33.33; -33.33 33.33];
C = [1 0; 0 1];
D = [0 0; 0 0];
```

*Halaman ini sengaja dikosongkan*

## **BIODATA PENULIS**