



PROPOSAL TUGAS AKHIR - TF 181801

**DETEKSI ANOMALI SUARA MESIN NORMAL DAN
ABNORMAL DENGAN METODE *SUPERVISED* DAN
*UNSUPERVISED LEARNING***

**BAGUS ADHI HERLAMBANG
NRP. 02311840000083**

Calon Dosen Pembimbing
Dr. Suyanto, S.T., M.T.
Bagus Tris Atmaja, S.T., M.T., Ph.D.

Departemen Teknik Fisika
Fakultas Teknologi Industri dan Rekayasa Sistem
Institut Teknologi Sepuluh Nopember
2021

Halaman ini sengaja dikosongkan

LEMBAR PENGESAHAN

PROPOSAL TUGAS AKHIR

PROGRAM STUDI SARJANA DEPARTEMEN TEKNIK FISIKA

Judul : **Deteksi Anomali Suara Mesin Normal dan Abnormal dengan Metode *Supervised dan Unsupervised Learning*.**

Bidang Minat : Vibrasi dan Akustik

Mata Kuliah Pilihan yang diambil : Sistem Audio
Komputasi Vibrasi

Identitas Pengusul

Nama : Bagus Adhi Herlambang

NRP : 02311840000083

Jenis Kelamin : Laki-laki

Jangka Waktu Pelaksanaan : 6 Bulan

Calon Pembimbing : Dr. Suyanto, S.T., M.T.
Bagus Tris Atmaja, S.T., M.T., Ph.D.

Status Pengusulan : Baru

Surabaya, 7 Januari 2022

Pengusul Proposal,

Bagus Adhi Herlambang
NRP. 02311840000083

Mengetahui,
Kepala Laboratorium
Vibrasi dan Akustik

Calon Dosen Pembimbing

Dr. Suyanto, S.T., M.T.,
NIP. 19711113 199512 1 002

Dr. Suyanto, S.T., M.T.,
NIP. 19711113 199512 1 002

Halaman ini sengaja dikosongkan

DAFTAR ISI

LEMBAR PENGESAHAN	iii
DAFTAR ISI.....	v
DAFTAR GAMBAR	vii
DAFTAR TABEL.....	ix
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Tugas Akhir	3
1.4 Batasan Masalah.....	3
1.5 Relevansi Tugas Akhir.....	3
BAB II TINJUAN PUSTAKA	5
2.1 Review Penelitian Sebelumnya.....	5
2.2 Teori Penunjang	9
BAB III METODE PENELITIAN.....	19
3.1 Studi Literatur	19
3.2 Pengumpulan Dataset.....	20
3.3 Persiapan <i>Training</i> Data.....	20
3.4 Ekstraksi Fitur	21
3.5 Pelaksanaan <i>Training</i> Data	21
3.6 Pelaksanaan <i>Testing</i> Data.....	22
BAB IV JADWAL KEGIATAN	23
DAFTAR PUSTAKA	25

Halaman ini sengaja dikosongkan

DAFTAR GAMBAR

Gambar 2.1 Prosedur ASD menggunakan Auto Encoder (Koizumi, et al., 2018)	5
Gambar 2.2 <i>Pipeline</i> dari GAN (Akçay, et al., 2018).	7
Gambar 2.3 Datasets yang digunakan (Akçay, et al., 2018).	7
Gambar 2.4 Performa pada MNIST (a) dan Fashion-MNIST (b) model BiGAN/EGBAD dan GANomaly diukur berdasarkan area di bawah kurva presisi-recall (AUPRC). Hasilnya telah dipilih sebagai hasil terbaik antara berbagai jenis pelatihan (Di Mattia, et al., 2021).	8
Gambar 2.5 <i>Outlier Classifier</i> untuk Klasifikasi Biner (Wang, et al., 2021).	9
Gambar 2.6 <i>ID Classifier</i> untuk Klasifikasi Ganda (Wang, et al., 2021).	9
Gambar 2.7 Overview Sistem Anomalous Sound Detection (Kawaguchi, et al., 2021)	11
Gambar 2.8 Convolution Layer. (a) <i>Standard Convolution Filters</i> , (b) <i>Depthwise Convolutional Filters</i> , (c) <i>Pointwise Convolution</i> . (Howard, et al., 2017)	13
Gambar 2.9 . Ilustrasi <i>semi-supervised learning</i> (Welling, et al., 2017)	14
Gambar 2.10 . Arsitektur <i>auto encoder</i> (Koizumi, et al., 2018).	16
Gambar 2.11 Grafik <i>Receiver Operating Characteristic</i> (Obuchowski, 2005). .	17
Gambar 2.12 Nilai AUC pada Grafik ROC (Zou, et al., 2007).	18
Gambar 3.1 Diagram Alir Penelitian	19

Halaman ini sengaja dikosongkan

DAFTAR TABEL

Tabel 3.1 <i>Overview</i> domain dataset pada training dan testing.	21
Tabel 4.1 Jadwal Kegiatan	23

Halaman ini sengaja dikosongkan

BAB I

PENDAHULUAN

1.1 Latar Belakang

Monitoring kondisi mesin merupakan kegiatan yang dilakukan untuk memastikan mesin berjalan sesuai dengan spesifikasi yang ada. Kegiatan monitoring kondisi mesin sangat berkaitan erat dengan kegiatan *maintenance* (Mohanty, 2015). Dengan adanya monitoring kondisi mesin, kesalahan dapat dideteksi secara dini, sehingga mengurangi terjadinya stop produksi yang berujung kerugian besar (Liang, et al., 2020).

Salah satu pengembangan *condition monitoring* di era industri 4.0 adalah *Anomalous Sound Detection* (ASD). ASD merupakan metode untuk mengidentifikasi apakah suara yang dipancarkan dari objek (mesin) normal atau tidak normal. ASD adalah teknologi penting dalam pengembangan teknologi industri 4.0 yang menyangkut otomatisasi (Kawaguchi, et al., 2021). Anomali dalam suara yang dihasilkan oleh mesin dapat menunjukkan adanya indikasi kesalahan atau kerusakan, dengan melakukan deteksi anomali lebih awal dapat menghindari serangkaian masalah terutama dalam hal pemeliharaan prediktif. Deteksi Anomali dapat dikategorikan sebagai *supervised learning*, *unsupervised learning*, dan *semi-supervised learning*. Metode *supervised learning* merupakan salah satu metode *deep learning* yang mengharuskan seluruh kumpulan data pelatihan diberi label "normal" atau "abnormal" dan metode ini pada dasarnya dilakukan pada klasifikasi biner. Pada metode *semi-supervised learning* hanya membutuhkan data yang dianggap "normal" untuk diberi label, dalam metode ini, model akan mempelajari seperti apa data "normal". Metode *unsupervised learning* melibatkan data yang tidak berlabel. Dalam teknik ini, model akan mempelajari data mana yang "normal" dan "abnormal" tanpa mengetahui kondisi dari data tersebut pada proses pelatihan (Nunez, 2021).

ASD merupakan deteksi anomali berbasis suara yang fleksibel dan dapat mengurangi biaya suatu perusahaan dalam hal monitoring kondisi mesin (*machine*

condition monitoring). ASD dilakukan dengan mengumpulkan data berupa suara mesin dengan cara mendekatkan mikrofon ke mesin. Data tersebut kemudian diolah dengan menggunakan *deep learning* untuk mendeteksi adanya anomali. Hal tersebut dapat menghindari kerugian besar yang disebabkan oleh kegagalan serius dengan menemukan kesalahan awal mesin dan melakukan perawatan secara efektif (Wang, et al., 2021).

Pada metode *supervised learning* data pelatihan berisi suara normal dan anomali. Model klasifikasi biner *supervised* cocok untuk deteksi anomali. Pada saat mesin sedang bekerja, sangat sulit untuk mengumpulkan data berupa suara mesin abnormal di industri sebenarnya. Sebagian besar suara normal digunakan sebagai data pelatihan. Hal tersebut membuat metode *unsupervised learning* lebih mudah untuk digunakan (Wang, et al., 2021). Beberapa metode menggunakan model *unsupervised* untuk mempelajari karakteristik penting dari suara normal sehingga menemukan subruang di mana sampel normal berada. Kemudian suara di luar subruang dinilai sebagai anomali dengan mengadopsi autoencoder sebagai anomali detektor, model dilatih dengan kesalahan rekonstruksi pada sampel normal dan anomali skor diturunkan dari kesalahan rekonstruksi (Wilkinghoff, 2020). Metode lain yang digunakan adalah *semi-supervised* dengan mengembangkan model *generative adversarial network* (GAN). Secara umum, GAN merupakan model yang memiliki dua *neural networks*, yaitu *generative* sebagai generator dan *adversarial* sebagai diskriminator. Generator bertujuan untuk menangkap distribusi data, sedangkan discriminator bekerja sebagai pendeteksi sampel yang ada merupakan sampel yang berasal dari input (*real*) atau hasil dari generator (*fake*) (Di Mattia, et al., 2021). Untuk menjalankan ketiga model yang digunakan, diperlukan *acoustic feature* sebagai *extractor* (Koizumi, et al., 2017). *Acoustic feature* yang digunakan kali ini adalah *log-mel energies* (Kawaguchi, et al., 2021). Mengembangkan metode *supervised*, *semi-supervised*, dan *unsupervised learning* untuk deteksi suara mesin normal dan abnormal memiliki potensi yang besar khususnya di bidang industri. Oleh karena itu disusun Tugas Akhir untuk mendeteksi anomali suara mesin normal dan abnormal dengan metode *supervised learning* dan *unsupervised learning*.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, maka rumusan masalah pada penelitian ini adalah bagaimana metode *supervised learning*, *semi-supervised learning*, dan *unsupervised learning* yang paling tepat untuk deteksi anomaly suara mesin normal dan abnormal.

1.3 Tujuan Tugas Akhir

Tujuan dilakukan penelitian ini adalah untuk menganalisis metode terbaik antara *supervised learning*, *semi-supervised learning*, dan *unsupervised learning* untuk deteksi anomaly suara mesin normal dan abnormal.

1.4 Batasan Masalah

Batasan masalah pada penelitian ini adalah:

- a. Masing-masing metode menggunakan jumlah parameter training yang sama.
- b. Penelitian ini tidak mendeteksi jenis kerusakan mesin yang dialami, melainkan hanya mendeteksi apakah mesin tersebut normal atau abnormal.

1.5 Relevansi Tugas Akhir

Penelitian yang diusulkan ini diharapkan memberi manfaat sebagai berikut:

- a. Mengurangi kemungkinan terjadinya kerusakan mesin karena adanya deteksi dini melalui suara *anomaly* mesin.
- b. Menawarkan alternatif untuk mengurangi biaya perawatan mesin.
- c. Menawarkan alternatif untuk mengurangi kemungkinan terjadinya *human error*.

Halaman ini sengaja dikosongkan

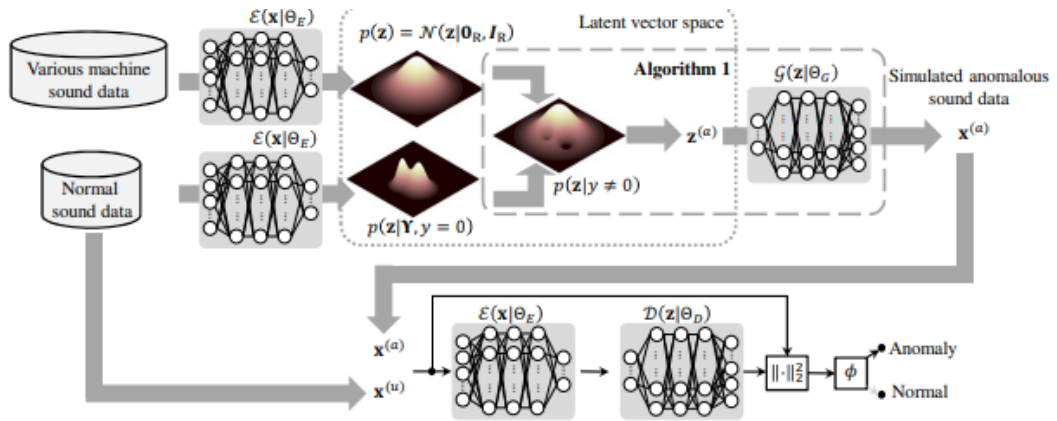
BAB II

TINJUAN PUSTAKA

2.1 Review Penelitian Sebelumnya

2.1.1 *Unsupervised Detection of Anomalous Sound based on Deep Learning and the Neyman-Pearson Lemma*

Permasalahan yang diangkat dalam penelitian ini adalah deteksi dini kerusakan mesin berdasarkan suara *anomaly* pada mesin atau *anomalous sound detection*. Jurnal ini menggunakan *deep learning* dengan metode Auto Encoder yang termasuk ke dalam *unsupervised learning*.



Gambar 2.1 Prosedur ASD menggunakan Auto Encoder (Koizumi, et al., 2018).

Berdasarkan Gambar 2.1, simbol ϵ diartikan sebagai encoder, D sebagai decoder, dan G sebagai generator. Encoder berfungsi menerima input kemudian direduksi menjadi vektor laten. Hasil dari proses encoder berupa vektor laten kemudian direkonstruksi menjadi seperti input vektor, kemudian *error* dari proses rekonstruksi dihitung dan dijadikan sebagai skor anomali. Generator digunakan untuk menghasilkan data normal palsu. Hasil yang diperoleh menunjukkan bahwa deteksi keusakan menggunakan *anomalous sound detection* dengan metodel *unsupervised* dapat dikembangkan lagi dan akan menghasilkan hasil yang lebih baik apabila menggunakan *supervised learning* dengan suara *anomaly* dijadikan sebagai input yang diketahui nilainya (Koizumi, et al., 2018).

2.1.2 *Unsupervised Anomalous Sound Detection for Machine Condition Monitoring under Domain Shifted Conditions*


Permasalahan yang diangkat dalam penelitian ini adalah melakukan deteksi dini kerusakan mesin berdasarkan suara tidak normal pada mesin. Metode yang digunakan dalam jurnal ini adalah MobileNet V2 dan Auto Encoder dengan menggunakan tujuh jenis suara mesin yang berbeda. Untuk menentukan keadaan mesin normal atau abnormal, *anomaly score* yang dilambangkan sebagai $A_0(x)$ ditentukan. Mesin akan ditentukan sebagai abnormal apabila nilai $A_0(x)$ melebihi nilai *threshold* (\emptyset) yang ditentukan sebagai parameter.

$$Decision = \begin{cases} Abnormal & [A_0(x) > \emptyset] \\ Normal & otherwise \end{cases} \quad (1)$$

Hasil yang diperoleh berupa nilai AUC dan pAUC, dimana nilai rata-rata setiap mesin metode MobileNet V2 adalah AUC = 62,6%, pAUC = 57,64% dan Auto Encoder adalah AUC = 63,47% dan pAUC = 53,53% (Kawaguchi, et al., 2021).

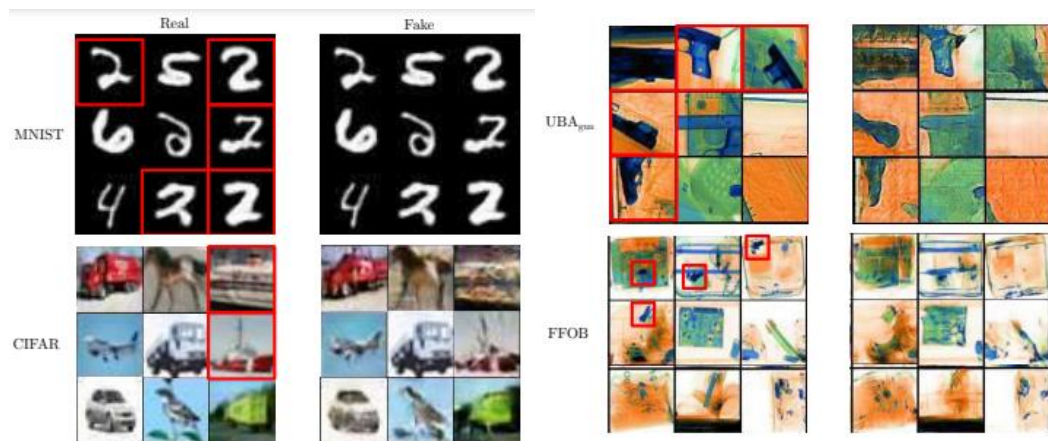
2.1.3 *GANomaly: Semi-Supervised Anomaly Detection via Adversarial Training*

Permasalahan yang diangkat dalam penelitian ini adalah melakukan deteksi *anomaly* dengan menggunakan pendekatan *semi-supervised learning* menggunakan *generative adversarial network* (GAN).



Gambar 2.2 Pipeline dari GAN (Akçay, et al., 2018).

Pada jurnal ini, deteksi *anomaly* dilakukan dengan menggunakan empat *dataset* yaitu dataset dari MNIST (berupa gambar angka), CIFAR, UBA (gambar senjata), dan FFOB yang dapat dilihat pada Gambar 2.3. Ide yang dikembangkan pada jurnal ini adalah terdapat dua *neural networks* (generator dan discriminator) yang saling bersaing satu sama lain untuk menghasilkan hasil yang maksimal. Generator akan menghasilkan gambar palsu, kemudian data hasil generator tersebut dideteksi oleh diskriminator. Pipeline lengkap dapat dilihat pada Gambar 2.2.




Gambar 2.3 Dataset yang digunakan (Akçay, et al., 2018).

Hasil yang diperoleh menunjukkan bahwa metode yang diusulkan mengungguli baik kontemporer berbasis GAN dan pendekatan deteksi *anomaly* berbasis autoencoder tradisional dengan kemampuan generalisasi untuk tugas deteksi anomali apa pun (Akçay, et al., 2018).

2.1.4 A Survey on GANs for Anomaly Detection

Jurnal ini membahas tentang perbandingan metode *generative adversarial network* yang digunakan. Pada penelitian di jurnal ini menggunakan *datasets* dari MNIST, Fashion-MNIST, CIFAR-10, dan KDD dataset. Metode yang digunakan mulai dengan mengumpulkan semua *datasets*. Mulai dari kumpulan besar, dipilih satu kelas sebagai anomali dan, setelah mengacak dataset, kemudian membuat set pelatihan dengan menggunakan 80% dari seluruh data sedangkan 20% sisanya digunakan untuk pengujian set, proses ini diulang untuk semua kelas dalam dataset. Setiap model dilatih sesuai dengan implementasi aslinya pada set pelatihan dan diuji pada seluruh dataset terdiri dari data reguler dan data anomali (Di Mattia, et al., 2021).

Hasil yang diperoleh pada metode BiGAN dan GANomaly dapat dilihat pada Gambar 2.4.

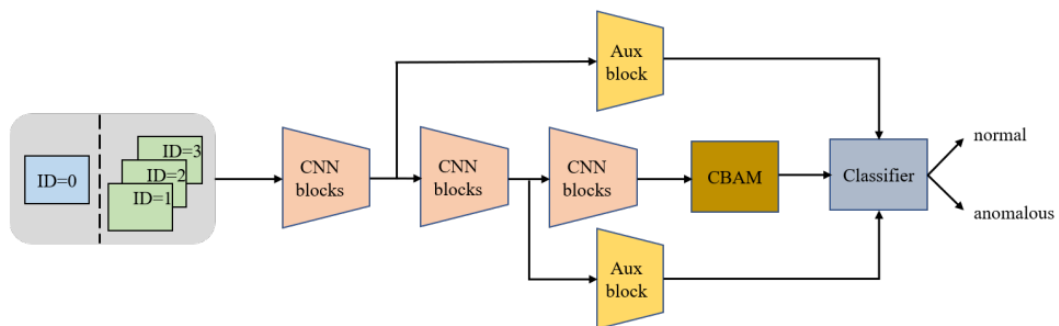


Gambar 2.4 Performa pada MNIST (a) dan Fashion-MNIST (b) model BiGAN/EGBAD dan GANomaly diukur berdasarkan area di bawah kurva presisi-recall (AUPRC). Hasilnya telah dipilih sebagai hasil terbaik antara berbagai jenis pelatihan (Di Mattia, et al., 2021).


2.1.5 Unsupervised Anomalous Sound Detection for Machine Condition Monitoring under Domain Shifted Conditions Using Classification-Based Method.

Permasalahan yang diangkat dalam penelitian ini adalah menyelesaikan *anomalous sound detection* dengan menggunakan pendekatan MobileNet. Dalam jurnal ini, *unsupervised anomaly detection* dirangkai ulang sebagai masalah *supervised classifier*. Untuk klasifikasi audio, CNN menunjukkan kinerja yang

baik, seperti ResNet, MobileFaceNet, MobileNet V3. Pada jurnal ini mengadopsi dua pengklasifikasi berdasarkan arsitektur populer untuk mendapatkan batas keputusan untuk mengidentifikasi apakah yang tak terlihat suara normal atau abnormal (Wang, et al., 2021). Pada jurnal ini digunakan dua metode yaitu, *outlier classifier* untuk klasifikasi biner, dan *ID classifier* untuk klasifikasi ganda. Pada *outlier classifier*, input mesin normal diberi nilai 0 (positif) yaitu pada mesin ID = 0, sedangkan untuk mesin abnormal diberi nilai -1 (negatif) yaitu pada mesin ID = 1, ID = 2, ID = 3. Sedangkan pada *ID classifier*, input diberi label berupa 0 sampai 3 dengan menggunakan MobileNet.



Gambar 2.5 *Outlier Classifier* untuk Klasifikasi Biner (Wang, et al., 2021).



Gambar 2.6 *ID Classifier* untuk Klasifikasi Ganda (Wang, et al., 2021).

Hasil yang diperoleh menunjukkan bahwa metode *supervised learning* menggunakan *outlier classifier* dan *ID classifier* jauh mengungguli metode *unsupervised learning* dengan nilai rata-rata AUC dan pAUC sebesar 95,82% dan 92,32% (Wang, et al., 2021).

2.2 Teori Penunjang


2.2.1 Condition Monitoring

Condition monitoring adalah proses pemantauan kondisi tertentu dalam mesin (seperti getaran, suhu, dll) untuk mengidentifikasi perubahan yang dapat menunjukkan kesalahan yang berkembang. *Condition monitoring* adalah bagian utama dari *predictive maintenance* karena penerapan pemantauan kondisi memungkinkan pemeliharaan terjadwal dan tindakan pencegahan diambil untuk mencegah kegagalan lebih lanjut dan kemungkinan adanya *downtime* yang tidak direncanakan di kemudian hari (Mohanty, 2015).

Condition Monitoring merupakan evolusi dari *predictive maintenance*. *Predictive maintenance* telah membuat kemajuan besar selama beberapa dekade terakhir. Saat ini, telah ditangani sebagai salah satu solusi paling inovatif untuk mengantisipasi kegagalan mesin dan digunakan oleh berbagai sektor industri. *Predictive maintenance* dapat diterapkan pada sektor industri besar karena dapat mencegah terjadinya *breakdown* sehingga memberikan keuntungan karena mengurangi biaya kegagalan yang mana harus mengganti komponen yang rusak. Oleh karena itu, hal ini dilakukan sebagai investasi dalam peralatan pengukuran dan sistem analisis (Carlos, et al., 2020).

2.2.2 Anomalous Sound Detection (ASD)

Anomalous sound detection (ASD) merupakan metode untuk mengidentifikasi apakah suara yang dipancarkan dari objek (mesin) normal atau tidak normal. ASD adalah teknologi penting dalam pengembangan teknologi industri 4.0 yang menyangkut otomatisasi (Kawaguchi, et al., 2021). ASD merupakan deteksi anomali berbasis suara yang fleksibel dan dapat mengurangi biaya suatu perusahaan dalam hal monitoring kondisi mesin (*machine condition monitoring*). ASD dilakukan dengan mendekatkan mikrofon ke mesin yang berbeda untuk mendeteksi adanya anomali. Hal tersebut dapat digunakan untuk menghindari kerugian besar dengan menemukan kerusakan awal mesin (Wang, et al., 2021).



Gambar 2.7 Overview Sistem Anomalous Sound Detection (Kawaguchi, et al., 2021).

ASD digunakan untuk memprediksi perilaku abnormal dibandingkan dengan perilaku normal yang diamati setelah menyiapkan sistem. Setelah mendeteksi anomali, pengklasifikasi mencoba mengidentifikasi kesalahan sistem berdasarkan kelas kegagalan yang telah ditentukan (Henze, et al., 2019).

2.2.3 *Short Time Fourier Transform (STFT)*

Short Time Fourier Transform merupakan penerapan dari *discrete fourier transform* (DFT) yang dilakukan secara berututan pada sinyal audio diskrit. Algoritma STFT adalah pengembangan dari FFT (*Fast Fourier Transform*). Sinyal akan dicuplik dalam waktu tertentu pada algoritma ini. Sinyal yang diterima akan diterjemahkan dalam domain frekuensi. Kemudian sinyal dicuplik selama t detik, sehingga sinyal tersebut akan diketahui posisinya dalam domain waktu dan frekuensi (Yani, et al., 2008).

Fast Fourier Transform (FFT) merupakan algoritma yang digunakan untuk merepresentasikan sinyal dalam domain waktu diskrit dan domain frekuensi. Proses FFT yang dilakukan berulang-ulang secara berurutan pada sinyal suara masukan ini disebut STFT. Metode overlap STFT digunakan agar hasil perubahan spectrum lebih halus yaitu dengan mengatur jarak antara frame FFT pertama dengan frame FFT berikutnya dengan *hop size* (Sari, 2019).

2.2.4 *Supervised Learning*




Algoritma *supervised learning* mengasumsikan ketersediaan *dataset* pelatihan yang telah diberi label. Sebagai contoh pada kelas normal dan anomali.

Kumpulan data normal dan abnormal masing-masing digabungkan dan diberi label. Kemudian, pelatihan dan pengujian *dataset* harus dipilih untuk validasi silang. Metode *supervised learning* digunakan untuk memodelkan *dataset* pelatihan. Salah satu penggunaan algoritma ini adalah pada *anomaly detection* (Arunraj, et al., 2017). Algoritma *supervised learning* terbagi lagi menjadi beberapa sub berdasarkan pendekatannya, yaitu *logic-based algorithms*, *perceptron-based algorithms*, dan *statistical learning algorithms* (Abdurrohman, et al., 2018).

- **MobileNet V2**

MobileNet V2 adalah *convolutional neural network* yang memiliki kedalaman 53 lapisan. MobileNet V2 merupakan pengembangan dari arsitektur *deep learning*. Pada tahun 2017, MobileNet V2 diciptakan oleh Google, MobileNet V2 mempunyai layer khusus yang disebut dengan *depthwise separable convolution*. Layer *depthwise separable convolution* ini digunakan untuk mereduksi kompleksitas dan lebih sedikit parameter sehingga menghasilkan model yang lebih ukurannya. Perkembangan lebih lanjut dari MobileNet adalah MobileNet V2. Pada MobileNet V2, dua fitur terbarunya adalah linear bottleneck pada setiap layer dan koneksi shortcut antara bottlenecks (Arunraj, et al., 2017).

MobileNet didasarkan pada arsitektur ramping yang menggunakan konvolusi yang dapat dipisahkan secara mendalam untuk membangun bobot yang ringan *deep neural network*. Model MobileNet didasarkan pada *depthwise separable convolution* yang merupakan bentuk konvolusi terfaktor yang memfaktorkan konvolusi standar menjadi *depthwise convolution* dan konvolusi 1×1 disebut *pointwise convolution*. Untuk MobileNet, konvolusi mendalam menerapkan filter tunggal ke setiap saluran input. *Pointwise convolution* kemudian menerapkan konvolusi 1×1 untuk menggabungkan hasil *depthwise convolution*. Konvolusi standar memfilter dan menggabungkan input menjadi satu set output baru dalam satu langkah. *Depthwise separable convolution* membagi ini menjadi dua lapisan, lapisan terpisah untuk penyaringan dan yang terpisah lapisan untuk menggabungkan. Gambar 2.8 menunjukkan standard konvolusi Gambar 2.8(a) kemudian difaktorkan menjadi *depthwise convolution* pada Gambar 2.8(b) dan *pointwise convolution* pada Gambar 2.8(c) (Howard, et al., 2017).

(a) *Standard Convolution Filters*(b) *Depthwise Convolutional Filters*(c) *Pointwise Convolution*

Gambar 2.8 Convolution Layer. (a) *Standard Convolution Filters*, (b) *Depthwise Convolutional Filters*, (c) *Pointwise Convolution*. (Howard, et al., 2017).

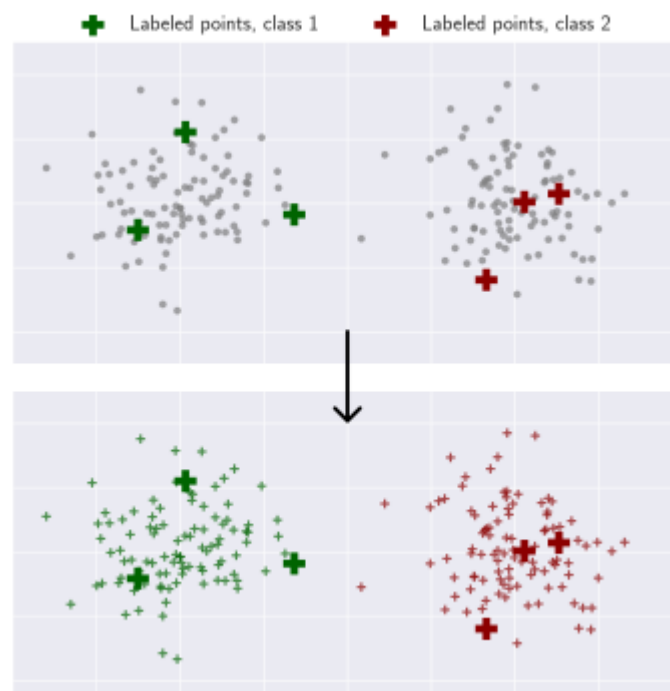
2.2.5 Semi-supervised Learning

Semi-supervised learning merupakan paradigma pembelajaran yang terkait dengan membangun model yang menggunakan data berlabel dan tidak berlabel. Metode *semi-supervised learning* dapat meningkatkan kinerja pembelajaran dengan menggunakan contoh tambahan data yang tidak berlabel dibandingkan dengan *supervised learning* yang hanya dapat menggunakan data berlabel. *Semi-supervised learning* bertujuan untuk memprediksi lebih akurat dengan bantuan data tidak berlabel dibandingkan dengan *supervised learning* yang hanya menggunakan data berlabel. Konsep *semi-supervised learning* pertama kali muncul pada era 1970. Metode paling awal telah ditetapkan sebagai pembelajaran mandiri, mekanisme berulang yang menggunakan inisial data berlabel untuk melatih model dan memprediksi beberapa sampel yang tidak berlabel. Kemudian prediksi terbaik dari model *supervised* menyediakan lebih banyak data pelatihan untuk algoritma *supervised*, sampai semua contoh yang tidak berlabel telah diprediksi. Metode Generatif dapat mempelajari fitur implisit data untuk model

distribusi data yang lebih baik. Model distribusi data nyata dari dataset pelatihan dan kemudian menghasilkan data baru hasil dari generative data. Di bagian ini, ditinjau metode *semi-supervised* berdasarkan Generatif Adversarial Network (GAN) (Yang, et al., 2021).

- **Generative Adversarial Network (GAN)**

GAN merupakan *neural network* yang terdiri dari Generator (G) dan Diskriminator (D). Generator berfungsi mempelajari distribusi data input. Generator (G) menghasilkan sampel palsu $G(z)$ yang digunakan untuk memanipulasi Diskriminator (D). Diskriminator sendiri berfungsi untuk membedakan antara Input data asli dengan data sampel hasil Generator (data palsu). Karena GAN dapat mempelajari distribusi data nyata dari sampel yang tidak berlabel. GAN termasuk ke dalam *semi-supervised learning* (Yang, et al., 2021).



Gambar 2 9. Ilustrasi *semi-supervised learning* (Welling, et al., 2017).

Dalam penelitian ini, GAN digunakan sebagai *anomaly detection*. Metode *semi-supervised learning* yang dirancang untuk digunakan dengan kumpulan data yang terdiri dari data berlabel dan tidak berlabel. Namun secara umum, metode ini mengasumsikan jumlah *instance* berlabel jauh lebih kecil daripada jumlah *instance* yang tidak berlabel. Hal ini karena data tidak berlabel cenderung lebih berguna

ketika kita memiliki beberapa contoh berlabel. Hal tersebut dapat dilihat pada Gambar 2.9 (Welling, et al., 2017).


2.2.6 *Unsupervised Learning*

Algoritma *unsupervised learning* adalah algoritma yang hanya membutuhkan titik data input, tidak dengan output dimana output diasumsikan ada. Algoritma ini dapat memiliki berbagai tujuan diantaranya *unsupervised generative models* umumnya ditugaskan untuk dapat menghasilkan titik data baru dari distribusi yang sama dengan data input, sementara rentang metode *unsupervised* lainnya difokuskan untuk mempelajari beberapa representasi baru dari input data (Welling, et al., 2017). Algoritma *unsupervised* bekerja dengan menganalisis data yang tidak berlabel untuk menemukan pola tersembunyi dan menentukan korelasinya. Pendekatan ini tidak menggunakan data training dan data test untuk melakukan prediksi maupun klasifikasi dengan tujuan mengelompokkan objek yang hampir sama dalam suatu area tertentu (Rezkie, 2021).

Beberapa metode menggunakan model *unsupervised* untuk mempelajari karakteristik penting dari normal suara sehingga menemukan subruang di mana sampel normal berada. Kemudian suara di luar subruang dinilai sebagai anomali mengadopsi autoencoder sebagai anomali detektor, model dilatih dengan kesalahan rekonstruksi pada sampel normal dan anomali skor diturunkan dari kesalahan rekonstruksi (Wilkinghoff, 2020). Salah satu metode *unsupervised learning* yang digunakan pada ASD adalah *auto encoder*.

- ***Auto Encoder***

Auto encoder adalah sebuah jaringan syaraf tiruan yang digunakan untuk mempelajari data yang tidak berlabel (*unsupervised learning*). *Autoencoder* memiliki dua bagian utama yaitu *encoder* yang memetakan input ke dalam kode, dan *decoder* yang memetakan kode ke rekonstruksi input (Kramer, 1991).




Gambar 2 10. Arsitektur *auto encoder* (Koizumi, et al., 2018).

Ide *Auto Encoder* telah populer selama beberapa dekade. Pengaplikasian pertama dimulai pada 1980-an. Aplikasi yang paling tradisional adalah *dimensionality reduction* atau *feature learning*, tetapi konsep tersebut menjadi banyak digunakan untuk mempelajari model data generative. Beberapa AI paling kuat di tahun 2010-an melibatkan *auto encoder* yang ditumpuk di dalam *deep neural network* (Liu & Wu, 2018).

2.2.7 Receiver Operating Characteristic (ROC)

Receiver Operating Characteristic (ROC) merupakan suatu garis terdapat pada kurva yang merepresentasikan hubungan antara sensitifitas dan spesifisitas (Kusmantoro, 2018). Kurva ROC terdiri dari plot *false positive rate* (FPR) atau 1 - spesifisitas pada sumbu horizontal, dan *true positive rate* (FPR) atau sensitifitas pada sumbu vertikal. Setiap titik pada kurva mewakili nilai sensitifitas dan spesifisitas berdasarkan *threshold* yang ditentukan. Gabungan antara setiap titik tersebut disebut dengan garis ROC (Obuchowski, 2005).




Gambar 2.11 Grafik *Receiver Operating Characteristic* (Obuchowski, 2005).

Kurva ROC dimulai dari koordinat (0,0) dan berakhir pada koordinat (1,1). Perbedaan nilai *threshold* akan mengakibatkan nilai sensitivitas dan spesifisitas yang berbeda dan membentuk kurva. Setelah mendapatkan kurva ROC, nilai AUC dapat ditentukan dengan menghitung besar nilai di bawah kurva ROC (Obuchowski, 2005).

2.2.8 *Area Under the Curve* (AUC)

Area under the curve (AUC) merupakan luas area yang terdapat di bawah kurva ROC. Nilai AUC digunakan sebagai indikator akurasi suatu model. Nilai AUC dinilai lebih efektif karena menggabungkan antara nilai sensitivitas dengan spesifisitas (Zou, et al., 2007).



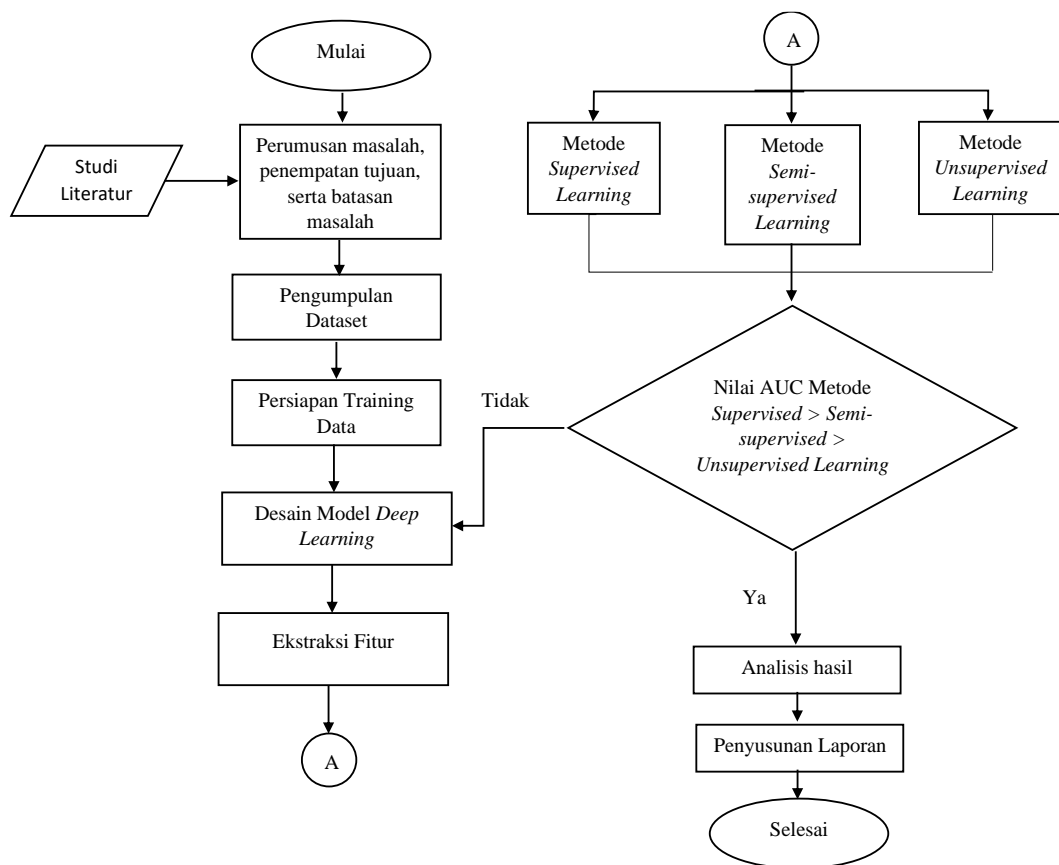
Gambar 2.12 Nilai AUC pada Grafik ROC (Zou, et al., 2007).

Berdasarkan Gambar 2.12 terdapat 3 garis pada kurva ROC. Nilai AUC pada garis A diketahui bernilai 1, nilai AUC pada garis C bernilai 0,5, sedangkan pada garis B nilai AUC adalah 0,85. Apabila nilai AUC berada $< 0,5$ maka hasil model yang didapat belum termasuk ke dalam kriteria baik (Zou, et al., 2007).

BAB III

METODE PENELITIAN

Dalam tugas akhir ini terdapat beberapa langkah-langkah penelitian yang akan dilakukan pada pengerjaan tugas akhir ini. Berikut penjelasan dari setiap langkah-langkah yang akan dikerjakan dalam pengerjaan tugas akhir ini pada Gambar 3.1.



Gambar 3.1 Diagram Alir Penelitian

3.1 Studi Literatur

Pada penelitian kali ini, studi literatur dilakukan sebagai Langkah awal dalam mengumpulkan teori-teori penunjang penelitian. Studi literatur dilakukan untuk mencari teori mengenai *supervised learning*, *semi-supervised learning*, dan *unsupervised learning*. Literatur yang dicari juga dijadikan acuan peneliti dalam menentukan hipotesis pada penelitian kali ini. Dari hasil studi literatur tersebut didapatkan 3 metode dalam melakukan penelitian ini yaitu MobileNet V2

(*supervised*), *generative adversarial networks* (*semi-supervised*), dan *auto encoder* (*unsupervised*).

3.2 Pengumpulan Dataset

Data yang digunakan pada penelitian tugas akhir kali ini merupakan data sekunder yang disediakan oleh *Detection and Classification of Acoustic Scenes and Events* (DCASE 2021) Task 2: *Unsupervised Anomalous Sound Detection for Machine Condition Monitoring under Domain Shifted Condition*. Data yang digunakan pada *training* merupakan data kondisi mesin normal. Data yang diperoleh terdiri dari 7 tipe mesin antara lain pump, gearbox, valve, fan, slide rail, toy train, dan toy car. Dataset berupa suara rekaman masing-masing mesin dalam keadaan normal. Setiap rekaman adalah audio berdurasi 10 detik yang mencakup suara pengoperasian mesin dan kebisingan lingkungan. Pengambilan *sampling rate* semua sinyal adalah 16 kHz. Kami mencampur suara mesin dengan kebisingan lingkungan, dan hanya rekaman bising yang tersedia sebagai data pelatihan/pengujian (Kawaguchi, et al., 2021).

3.3 Persiapan Training Data

Setelah data sekunder dikumpulkan, kemudian data disusun berdasarkan 3 metode yang sudah ditentukan. Berikut merupakan *setup* direktori pada penelitian Tugas Akhir ini. Dataset terdiri dari *development dataset*, *additional training dataset*, dan *evaluation dataset*.

- *Development Dataset*

Pada bagian ini terdiri dari 5 *section* untuk setiap mesin (*section 00*, *section 01*, *section 01*) dan setiap bagian adalah satu set lengkap pelatihan dan data uji. Untuk setiap *section*, dataset ini menyediakan (i) 1.000 klip suara normal dalam *domain source* untuk pelatihan, (ii) tiga klip suara normal dalam *target domain* untuk pelatihan, (iii) sekitar 100 klip suara normal dan anomali di domain sumber untuk pengujian, dan (iv) sekitar 100 klip masing-masing normal dan suara anomali dalam domain target untuk pengujian. Setelah training dilakukan, terdapat 3 tambahan *section* lagi yaitu (*section 03*, *section 04* dan *section 05*). Setiap *section* terdiri dari (i) sekitar

1.000 klip suara normal dalam domain sumber untuk pelatihan dan (ii) hanya tiga klip suara normal di domain target untuk pelatihan.

- *Evaluation Dataset*

Menyediakan klip uji untuk tiga *section* (Bagian 03, 04, dan 05) yang identik dengan data tambahan sebelumnya. Setiap bagian terdiri dari (i) klip uji di *source domain* dan (ii) klip uji di *target domain*, tidak ada yang memiliki label kondisi (yaitu, normal atau anomali). *Section* dari dataset evaluasi (Bagian 03, 04, dan 05) berbeda dari set data pengembangan (Bagian 00, 01, dan 02).

Tabel 3.1 Overview domain dataset pada training dan testing.

Dataset Domain	Source		Target	
	Normal	Abnormal	Normal	Abnormal
Training	1000	0	3	0
Testing	100	100	100	100

3.4 Ekstraksi Fitur

Sinyal audio berdurasi 10 detik pada awalnya dilakukan ekstraksi fitur dengan menggunakan STFT, yaitu sinyal audio dibagi menjadi frame-frame yang sesuai dengan panjang dari sinyal tersebut dan frekuensi samplingnya. Sinyal suara ditransformasikan ke dalam domain waktu – frekuensi dengan menggunakan algoritma STFT. Jarak antara frame awal dengan frame berikutnya yang akan diproses disebut dengan *hop size*. Pada penelitian ini menggunakan *frame size* 64 ms dengan 50% *hop size*, 64 jumlah *frames*, serta 128 jumlah *mel filters*.

Setelah dilakukan ekstraksi fitur menggunakan STFT, hasil fitur dari STFT kemudian ditransformasikan dalam bentuk *mel frequency scale*. Selanjutnya nilai logaritma dari *mel spectrogram* dihitung sehingga dihasilkan *log mel spectrogram* yang dijadikan sebagai input pada proses *training* menggunakan metode MobileNet V2 (*supervised*), *generative adversarial networks* (*semi-supervised*), dan *auto encoder* (*unsupervised*).

3.5 Pelaksanaan Training Data

Pada penelitian ini proses *training* data dilakukan satu per satu, mulai dari metode MobileNet-V2, GAN, dan *Auto Encoder*. Proses *training* dilakukan menggunakan bahasan pemrograman python versi 3.9.5. Proses training data dilakukan menggunakan dataset yang sama yang berasal dari data sekunder *Detection and Classification of Acoustic Scenes and Events* (DCASE 2021) Task 2: *Unsupervised Anomalous Sound Detection for Machine Condition Monitoring under Domain Shifted Condition*. Data tersebut sejatinya sudah memiliki label. Namun, untuk *semi-supervised* dan *unsupervised learning* yang mana dataset tidak memerlukan label, dataset yang digunakan mengabaikan label yang ada saat proses *training* data.

3.6 Pelaksanaan *Testing* Data

Testing data dilakukan untuk mengetahui keakuratan model *training* yang telah dibuat pada proses *training*. Hasil pengujian ditentukan berdasarkan *Area Under the Curve* (AUC) dan parsial-AUC (pAUC). pAUC adalah AUC yang dihitung dari sebagian kurva ROC di atas rentang minat yang telah ditentukan sebelumnya. AUC dan pAUC untuk masing-masing jenis mesin, bagian, dan domain didefinisikan sebagai:

$$AUC_{m,n,d} = \frac{1}{N_-N_+} \sum_{i=1}^{N_-} \sum_{j=1}^{N_+} H(B_{\theta,j,i}) \quad (2)$$

$$pAUC_{m,n,d} = \frac{1}{[pN_-]N_+} \sum_{i=1}^{[pN_-]} \sum_{j=1}^{N_+} H(B_{\theta,j,i}) \quad (3)$$

Dimana:

$$(B_{\theta,j,i}) = A_{\theta}(x_j^+) - A_{\theta}(x_i^-) \quad (4)$$

Alasan tambahan penggunaan pAUC didasarkan pada persyaratan praktis. Jika sistem ASD sering memberikan alarm *fals*, hal tersebut tidak bisa terus dipercaya. Oleh karena itu, penting untuk meningkatkan tingkat *true positive* di bawah kondisi FPR rendah. Di dalam penelitian tugas akhir ini digunakan $p=0,1$.

BAB IV

JADWAL KEGIATAN

Tugas akhir ini direncanakan untuk diselesaikan selama 6 bulan dengan jadwal kegiatan seperti ditunjukkan pada Tabel 4.1.

Tabel 4.1 Jadwal Kegiatan.

No	Kegiatan	Bulan 1				Bulan 2				Bulan 3				Bulan 4				Bulan 5				Bulan 6			
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
1	Studi Literatur																								
2	Pengumpulan Data																								
3	Desain Model <i>Deep Learning</i>																								
4	Proses Training dan Testing																								
5	Analisis Data																								
6	Penyusunan Laporan																								

Halaman ini sengaja dikosongkan

DAFTAR PUSTAKA

Howard, A. G. et al., 2017. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Application. *arXiv:1704.04861 [cs.CV]*.

Abdurrohman, H., Dini, R. & Muharram, A. P., 2018. Evaluasi Performa metode Deep Learning untuk Klasifikasi Citra Lesi Kulit The. *Seminar Nasional Instrumentasi, Kontrol dan Otomasi (SNIKO) 2018*.

Akcay, S., Atapour-Abarghouei, A. & Breckon, T. P., 2018. GANomaly: Semi-Supervised Anomaly Detection via Adversarial Training. *ACCV 2018*.

Arunraj, N. S. et al., 2017. Comparison of Supervised, Semi-supervised and Unsupervised Learning Methods in Network Intrusion Detection System (NIDS) Application. *Anwendungen und Konzepte der Wirtschaftsinformatik*, p. 1.

Blanke, M., 1999. *Fault Tolerant Control Systems*. London: Adventure Workd Press.

Carlos, J., Correa, J., A., A. & Guzman, L., 2020. *Mechanical Vibrations and Condition Monitoring*. s.l.:s.n.

Di Mattia, F., Galeone, P., De Simoni, M. & Ghelf, E., 2021. A Survey on GANs for Anomaly Detection. pp. 1-16.

Errabelli, R., 2012. Fault-Tolerant Voltage Source Inverter for Permanent Magnet Drives. *IEEE Transactions on Power Electronics*, Volume 27.

Hantoro, R. et al., 2018. Innovation in Vertical Axis Hydrokinetic Turbine – Straight Blade Cascaded (VAHT-SBC) design and testing for low current speed power generation. *Journal of Physics*, pp. 1-8.

Henze, D., Gorishti, K., Bruegge, B. & Simen, J.-P., 2019. AudioForesight: A Process Model for Audio Predictive Maintenance in Industrial Environments. *18th IEEE International Conference On Machine Learning And Applications (ICMLA)*.

Kawaguchi, Y. et al., 2021. *Description and Discussion on DCASE 2021 Challenge Task 2 : Unsupervised*. s.l., s.n.

Koizumi, Y., Kawachi, Y. & Harada, N., 2018. Unsupervised Detection of Anomalous Sound based on Deep Learning and the Neyman-Pearson Lemma. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*.

Koizumi, Y., Saito, S., Uematsu, H. & Harada, . N., 2017. Optimizing Acoustic Feature Extractor for Anomalous Sound Detection Based on Neyman-Pearson Lemma. *25th European Signal Processing Conference (EUSIPCO)*, pp. 1-5.

Kramer, M. A., 1991. Nonlinear Principal Component Analysis Using Autoassociative Neural Networks. *AIChE Journal*.

Kusmantoro, Z. N., 2018. Akurasi Uji Diagnostik Menggunakan Luasan Bawah Kurva ROC Smothed Empirical. *Program Studi Statistika, Departemen Matematika, Fakultas MIPA, UGM*.

Liang, X., Duan, F., Bennett, I. & Mba, D., 2020. A Sparse Autoencoder-Based Unsupervised Scheme.

Liu, Y. & Wu, L., 2018. High Performance Geological Disaster Recognition using Deep Learning. *Procedia Computer Science 139 (2018) 529–536*.

Mohanty, A. R., 2015. *Machinery Condition Monitoring: Principles and Practices*. s.l.:Taylor & Francis Group.

Nunez, E. C., 2021. Anomalous Sound Detection with Machine Learning: A Systematic Review.

Obuchowski, N. A., 2005. Fundamentals of Clinical Research for Radiologists. In: *ROC Analysis*. s.l.:American Journal of Roentgenology.

Rezkia, S. M., 2021. *Dqlab*. [Online] Available at: <https://www.dqlab.id/algoritma-supervised-vs-unsupervised-learning>

Sari, K. D., 2019. Deteksi Onset Pada Sinyal Musik gamelan Berdasarkan Skala Mel dan Bark Menggunakan Elemen Neural Networks. *Master Tesis Institut Teknologi Sepuluh Nopember*.

Wang, Y. et al., 2021. Unsupervised Anomalous Sound Detection for Machine Condition Monitoring Using Classification-Based Methods. pp. 1-7.

Welling, M., Choen, T., Gavves, E. & Schoneveld, L., 2017. *Semi-Supervised Learning with Generative Adversarial Network*. s.l.:Faculteit der Natuurkunde, Wiskunde en Informatica.

Wilkinghoff, K., 2020. *Anomalous Sound Detection With Look, Listen, and Learn Embeddings*, s.l.: DCASE 2020.

Yang, X., Song, Z., King, I. & Xu, Z., 2021. A Survey on Deep Semi-supervised Learning.

Yani, K., Rizal, A. & Prasetya, B., 2008. Analisis Kinerja Algoritma Short Time Fourier Transform (STFT) untuk Deteksi Sinyal Carrier frequency hopping Spread Spectrum (FHSS) CDMA. *Seminar Sistem Informasi Indonesia (SESINDO2008)*.

Zou, K. H., O'Malley, A. J. & Mauri, L., 2007. Receiver-Operating Characteristic Analysis for Evaluating Diagnostic Tests and Predictive Models. Volume 115.